

La f. di verosimiglianza può essere diversa,
ma il θ_{MAGN} deve essere lo stesso.

PRINCIPIO DI VEROSIMIGLIANZA) DA VEDERE

TROVARE K MAX

① posso calcolare logaritmo $\log L_n$

$$= \left(\sum x_i \right) \log \theta + (n - \sum x_i) \log (1 - \theta)$$

② Derivata

$$\frac{d \log L}{d \theta} = \frac{\sum x_i}{\theta} - \frac{(n - \sum x_i)}{1 - \theta}$$

$$= \frac{\sum x_i (1 - \theta) - \theta (n - \sum x_i)}{\theta (1 - \theta)}$$

$$= \frac{\sum x_i - n \theta}{\theta (1 - \theta)} \quad (\text{SEGNO})$$

$$\hat{\theta} = \frac{\sum x_i}{n}$$

DERIVATA SECONDA

$$= \frac{\sum x_i}{\theta^2} - \frac{(n - \sum x_i)}{(1 - \theta)^2}$$

(ESEMPIO 2)

$\{\mathcal{L}, F, P_\theta\}$ $X_1, \dots, X_n$ exp

$$f(x) = \lambda e^{-\lambda x} \quad x \geq 0$$

$$\frac{1}{\theta} e^{-\frac{x}{\theta}} \quad x \geq 0$$

$$L(\lambda; x_1, \dots, x_n) = \lambda^n e^{-\lambda \sum_{i=1}^n x_i}$$

$$\textcircled{1} \log L_n = n \log(\lambda) - \lambda \sum_{i=1}^n x_i$$

$$\textcircled{2} \frac{d \log L_n}{d\lambda} = \frac{n}{\lambda} - \sum_{i=1}^n x_i$$

A CAPA con
 $\frac{1}{\theta} e^{-\frac{1}{\theta} x}$

$$\hat{\lambda} = \frac{n}{\sum x_i}$$


$$\textcircled{3} \frac{d^2 \log L}{d\lambda^2} = -\frac{n}{\lambda^2}$$

è invariante e distorsione, o una o l'altra

$$E\hat{\theta} = \sum \underbrace{E x_i}_{=0} = 0$$

$$E\hat{\lambda} = E\left(\sum_{i=1}^n x_i\right) \stackrel{???}{=} E\left(\sum_{i=1}^n x_i\right) \stackrel{?}{=} \frac{n}{n\theta} = \frac{1}{\theta} = 1$$

↑ NO, PER JENSEN



$$Eg(x) > g(E(x))$$

ESEMPIO 3

$$\frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$$

$$x_1, \dots, x_n \sim N(\mu, \sigma^2) \text{ i.i.d.}$$

$$L(\mu, \sigma^2; x_1, \dots, x_n) = \frac{1}{(2\pi)^{n/2}} \frac{1}{(\sigma^2)^{n/2}} e^{-\frac{1}{2} \sum_{i=1}^n \left(\frac{x_i - \mu}{\sigma^2}\right)^2}$$

$$\log L = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{1}{2} \sum_{i=1}^n \frac{(x_i - \mu)^2}{\sigma^2}$$

$$\frac{\partial \log L}{\partial \mu} = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) = 0 \Rightarrow$$

$$\hat{\mu} = \frac{1}{n} \sum x_i$$

$$\frac{\partial \log l}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - \mu)^2$$

(per caso) $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x}_n)^2$

(NON SI PUÒ DIMOSTRARE LA NON DISTORSIONE)

È CONSISTENTE?

DEF: DISTANZA DI KULLBACK-LEIBLER

ABBIAMO A CHE FARE CON DELLE DENSITÀ f e g

$$D(f, g) = \int \ln \left(\frac{f(x)}{g(x)} \right) f(x) dx$$

$f(x)$ ASSOLUTAMENTE CONTINUA RISPETTO A $g(x)$

$$f(x) \ll g(x)$$

$$g(x) = 0 \Rightarrow f(x) = 0$$

Se $f(x) = 0$?

$$\lim_{x \rightarrow 0} x \ln x = 0$$

VA BENE IL TERMINE DISTANZA MA NON METRICA

PERCHÉ NON È SIMMETRICA

OSS

① NON È SIMMETRICA

$$D(f, g) \neq D(g, f)$$

② Se $f = g$ $D(f, g) = 0$

③ $D(f, g) > 0$ $f \neq g$

INTUITIONE: I punti di f sono PESATI di più



$$D(f, g) = \int \ln \left[\frac{f(x)}{g(x)} \right] f(x) dx$$

ASSO MIGLIA AL VALOR MEDIO, DA CAPIRE SI LOG

$$= E_f \left[\ln \left[\frac{f(x)}{g(x)} \right] \right] = E_f \left[- \ln \left[\frac{g(x)}{f(x)} \right] \right]$$

il meno serve
perché adesso è
convessa e posso
usare Jensen

DEF DI
VALOR MEDIO
 $\int$ DENSITA' $\times \dots$



$$\textcircled{7} - \ln \left(\frac{E[g(x)]}{f(x)} \right) = - \ln \int \frac{f(x)}{f(x)} dx \quad (=0)$$

$\downarrow$
 per def di valor medio $\downarrow$
 per def di valor medio $-\ln(1) = 0$

l'integrale della densità è $\textcircled{1}$

l'integrale va fatto su punti in cui $g(x) > 0$

$D(f, g)$?? entropia

$$-\sum_i p_i \ln p_i$$

$\downarrow$
distanza fra due stati

i : tutte le configurazioni di uno stato macroscopico

Possiamo scrivere lo $\log L$ in termini di K-L

$$L(\theta; x_1, \dots, x_n) = \prod_{i=1}^n f(x_i; \theta)$$

$$\log L = \ln \left(\theta; \underbrace{x_1, \dots, x_n}_{\text{parametro}} \right) = \sum_{i=1}^n \log(f(x_i; \theta))$$

$\downarrow$
v.c. θ generale da un modello dove θ è quello vero

$$l_n(\theta) - l_n(\hat{\theta}) = \text{costante che non conosciamo}$$

$$= \sum \log f(x_i, \theta) - \sum \log f(x_i, \hat{\theta}) - D$$

$$= \frac{1}{n} \sum_{i=1}^n \log \left(\frac{f(x_i, \theta)}{f(x_i, \hat{\theta})} \right) \longrightarrow \int \log \left(\frac{f(x, \theta)}{f(x, \hat{\theta})} \right) dx$$

$K_n(\theta, \hat{\theta})$

$$\arg \max_{\theta} L = \arg \max_{\theta} \log l = \arg \max_{\theta} l_n \quad \downarrow$$


$\hat{\theta}$ perché
il valore
medio rispetto
alla vera media

IDEA PER DIM LA CONSISTENZA

$$① M_n(\theta, \hat{\theta}) = \frac{1}{n} \sum_{i=1}^n \log \left[\frac{f(x_i, \theta)}{f(x_i, \hat{\theta})} \right]$$

$$② M_n(\theta, \hat{\theta}) \xrightarrow{?} -D(f_{\hat{\theta}}, f_{\theta}) = -D(\hat{\theta}, \theta)$$

$$③ P(|\theta_{MLE} - \hat{\theta}| > \sigma) \rightarrow 0$$



TH (CONSISTENZA MLE)

$$M_n(\theta, \hat{\theta}) = \frac{1}{n} \sum_{i=1}^n \log \left(\frac{f(x_i, \theta)}{f(x_i, \hat{\theta})} \right)$$


$$M(\theta) = M(\theta, \hat{\theta}) = -D(\hat{\theta}, \theta)$$

IPOTESI:

$$\sup_{\theta} |M_n(\theta, \hat{\theta}) - M(\theta)| \xrightarrow{P} 0$$

deve avvenire in contemporanea per tutti i θ

$$\sup_{\theta - \hat{\theta} > \delta} |M(\theta) - M(\hat{\theta})| > \varepsilon \quad \textcircled{A}$$



escludi ^{di} la funzione limite
sta piatta

il parametro non deve essere
lontano dal max


ALLORA

$$\begin{array}{c} \theta_{ML} \\ \text{"} \\ \text{arg max} \end{array} \xrightarrow{P} \hat{\theta}$$

DIM

$$A \Rightarrow B$$

$$P_r(A) \leq P_r(B)$$



se copio A, copio B

$$P(|M(\hat{\theta}) - M(\theta)| > \epsilon) \longrightarrow 0 \quad (B)$$

$$= M(\hat{\theta}) - M_n(\hat{\theta}) + M_n(\hat{\theta}) - M(\theta_{ML})$$

$M_n(\theta_{ML}) \geq M(\hat{\theta})$

$$\leq M(\hat{\theta}) - M_n(\hat{\theta}) + \overbrace{M_n(\theta_{ML})}^{\text{MAX}} - M(\theta_{ML})$$

$$\leq \underbrace{|M(\hat{\theta}) - M_n(\hat{\theta})|}_{\xrightarrow[p]{\text{per Hip}}} + \underbrace{|M_n(\theta_{ML}) - M(\theta_{ML})|}_{\xrightarrow[p]{\text{per Hip}}}$$

va bene anche
con LGN

per questo no
DA RIVEDERE

USANDO LA SECONDA HIP,

(ABBIAMO DIMOSTRATO SENZA SAPERE LA VERA FORMA DEL
STIMATORE $\hat{\theta}$)


lez 13 (10/11)

DIMOSTRIAMO L'ASINTOTICA GAUSSIANA

CONDIZIONI REGOLARITÀ

- ① $l(\theta) = \log L(\theta) \in C^2$ (ha 2 derivate continue)
- ② θ_0 (il vero valore del parametro, quello che massimizza)
 $\in \text{Int}(\Theta)$ (sta all'interno, e non sulla frontiera)

↓
insieme dei
valori ammissibili
per $\theta_0 \in \mathbb{R}$



- ③ PUÒ SCAMBIARE DUE VOLTE DERIVATE E INTEGRALE di $l(\theta)$

$$\frac{\partial}{\partial \theta} \underbrace{\int f(x; \theta) dx}_{h(\theta)}$$

$$\int \frac{\partial}{\partial \theta} \bar{f}(x; \theta) dx$$

- ④ v.a. IID

- ⑤ Valgono le condizioni di consistenza

- ⑥ $E\left[\frac{\partial^2 l}{\partial \theta^2}\right] < \infty$

LA 3 e la 6 sono le HIP non Locali

TEOREMA: Sotto le ipotesi ①-⑥ θ_0 vero valore del parametro

$$\frac{\hat{\theta} - \theta_0}{\sqrt{\text{VAR}(\hat{\theta})}} \xrightarrow{d} N(0, 1) \quad \left(\begin{array}{l} \text{lo stimatore } \hat{\theta} \\ \text{asintotico} \\ \text{gaussiano} \end{array} \right)$$

$$\hat{\theta}_{p \times 1} \quad \sqrt{n} (\hat{\theta} - \theta_0) \xrightarrow{d} N \left(0_{p \times 1}, E \left[\left(\frac{\partial \log L}{\partial \theta} \right)^2 \right]_{p \times p} \right)$$

DEF FUNZIONE PUNTEGGIO (SCORE FUNCTION)

$$S_n(\theta) = \frac{\partial}{\partial \theta} \log L_n(\theta; X_1, \dots, X_n) \quad (\text{dim } 1)$$

$$\nabla_{\theta} \log L_n(\theta, X_1, \dots, X_n) \quad (\text{dim } p)$$

LEMMA: $E[S_n(\theta)] \Big|_{\theta = \theta_0} = 0$

$S_n(\hat{\theta}) = 0$, ma ci aspettiamo che
 $\downarrow$
 stimatore
 in media sia 0,
 (derivata calcolata in θ_0)

Sin

$$P=1$$

integrale della f. densità (vale sempre 1 in $-\infty, \infty$)

$$0 = \frac{\partial}{\partial \theta} 1 = \frac{\partial}{\partial \theta} \int_{\mathbb{R}} f(x; \theta) dx$$

$$\stackrel{(3)}{=} \int_{\mathbb{R}} \frac{\partial}{\partial \theta} \underbrace{f(x; \theta)}_{\substack{\text{def } \frac{\partial}{\partial \theta} \log f(x; \theta)}} dx = \int_{\mathbb{R}} \underbrace{\frac{\partial}{\partial \theta} \frac{f(x; \theta)}{f(x; \theta)}}_{\substack{\text{def } \frac{\partial}{\partial \theta} \log f(x; \theta)}} f(x; \theta) dx$$

la loglik è una somma di f. densità
quindi va bene uno solo f di densità

$$\stackrel{\text{def}}{=} \mathbb{E} \left[\frac{\partial}{\partial \theta} \log f(x; \theta) \right] = 0$$

ESEMPIO

$$X \sim N(\mu, 1)$$

$$L: \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}(x-\mu)^2}$$

$$\log L = -\frac{1}{2} \log(2\pi) - \frac{1}{2}(x-\mu)^2$$

derivato $x - \mu \longrightarrow \mathbb{E}(x - \mu) = \mu_0 - \mu \xrightarrow{\uparrow} 0$

Lemma

Softo le Hip ① - ⑥

$$\text{VAR}(S(\theta)) = E\left[\left(\frac{\partial \log L}{\partial \theta}\right)^2\right]_{\theta=\theta_0} = -E\left[\frac{\partial^2 \log L}{\partial \theta^2}\right]_{\theta=\theta_0}$$

$\nearrow p=1$

Si $p = k > 1$

$$E\left[\left(\nabla \log L\right) \left(\nabla \log L\right)^T\right] = -E\left[H \log L\right]$$

$p \times 1$ $1 \times p$

Hessiana

MATRICE DI

INFORMAZIONE

Dim $p=1$

$$\frac{\partial}{\partial \theta} 0 = 0 = \frac{\partial}{\partial \theta} \int \frac{\partial \log f}{\partial \theta} f(x; \theta) dx$$

$$\textcircled{3} = \int \frac{\partial^2 \log f}{\partial \theta^2} f(x; \theta) dx + \int \frac{\partial \log f}{\partial \theta} \frac{\partial f(x; \theta)}{\partial \theta} dx$$

devo far comparire

lo derivato del logaritmo

$$= \int \frac{\partial^2}{\partial \theta^2} \log f(x; \theta) dx + \int \frac{\partial \log f}{\partial \theta} \frac{\partial}{\partial \theta} \frac{f(x; \theta)}{f(x; \theta)} dx$$

derivata
logaritmica

THM Sotto CR ①-⑥

$$\sqrt{n} (\hat{\theta}_{MLE} - \theta_0) \rightarrow_d N(0, \text{In}(\theta_0)^{-1})$$

matrice di informazione

$$\text{In}(\theta_0) = -E \left[\frac{\partial \log l}{\partial \theta} \frac{\partial \log l}{\partial \theta} \right]_{\theta = \theta_0}$$

DIM $p=1$

$$l'_n(\hat{\theta}) = l'(\theta_0) + l''(\bar{\theta})(\hat{\theta} - \theta_0)$$

(derivata)


↑

espansione
di Lagrange
con errore vero

Th di Lagrange

$$\exists \bar{\theta} \in [\theta_0, \hat{\theta}]$$

$l'_n(\bar{\theta})$ quanto vale? Vale 0 per la ②



PERCHÉ NO ANCHE?

lo ② vale con θ_0 (vero) MA POICHÉ È
CONSISTENTE, $\hat{\theta}$ È INTERNO QUINDI PER $n \rightarrow \infty$
VALE 0

$$-(\hat{\theta} - \theta_0) = \frac{l'(\theta_0)}{\underbrace{l''(\bar{\theta})}_{\neq 0}}$$

$$\Rightarrow -\sqrt{n}(\hat{\theta} - \theta_0) = \frac{l'_n(\theta_0)/\sqrt{n}}{l''_n(\bar{\theta})/\sqrt{n}}$$

poich l_n è la $\log L \Rightarrow$ somma di $\log$, $\Rightarrow$

ho il TLC $\Rightarrow$ IID, LEMMA 1 ($E=0$), LEMMA 2

$$= \frac{\sum_{i=1}^n \log f(\theta_0, x_i)}{\sum_{i=1}^n \log f(\bar{\theta}, x_i) / n} \quad \text{applico TLC}$$

$\longrightarrow$

$$\sum_{i=1}^n \log f(\bar{\theta}, x_i) / n \quad \times$$

LEMMA 2

$$\frac{1}{n} \sum_{i=1}^n \log f(x_i, \theta)$$

do

LEGGE GRANDI NUMERI

UNIFORMEMENTE INTEGRABILE (IID, $E=0$)

$$= \frac{\rightarrow N(0, I_1(\theta_0))}{- I_1(\theta_0)} \quad \text{oss. sola} \quad \left(\text{PER SLUSKY, PASSO DA } \bar{\theta} \text{ a } \theta_0 \right)$$

*: Il vettore medio è la matrice di informazione

$$= N(0, I^{-1}(\theta_0)) \quad \text{perché la varianza è un operatore quadratico}$$

$$\left(\int \hat{\theta} - \theta_0 \right)$$

NON CI DA FASINO

ESEMPIO POISSON, BERNO., EXP, GAUSSIANA
(DA FARE)

ESEMPIO NEGATIVO (IL THM NON FUNZIONA)

$x_1, \dots, x_n \sim N[0, \theta]$ dipende da θ
quindi non vale la condizione (3)

$$L(\theta; x_1, \dots, x_n) = \prod_{i=1}^n \frac{1}{\theta} \mathbb{1}_{[0, \theta]}(x_i)$$

max valore delle $x = \frac{1}{\theta^n} \mathbb{1}_{[0, \theta]}(\underbrace{x_{(n)}}_{x_1, \dots, x_n})$

$$\hat{\theta}_{MLE} = x_{(n)}$$

$$P_r\left(\underbrace{(\theta_0 - x_{(n)})}_{\theta} > \varepsilon\right) = P_r\left[\theta_0 - x_{(n)} > \frac{\varepsilon}{n}\right]$$



↳ p che le v.a. caschino
 - la densità è $\frac{(1 - \frac{\varepsilon}{\theta})^n}{\theta}$
 e $\xrightarrow{n \rightarrow \infty} -\frac{\varepsilon}{\theta}$

NON VALE IL THM.

ESEMPI E ESERCIZI

ES 1

METODO DEI MOMENTI

$X_i \sim \text{Bin}(K, p)$ osservazioni

$X_i: i = 1, \dots, n$

ES 2

$X_i: i = 1, \dots, n$ GAMMA (α, β)

Funzione Gamma $\alpha > 0$

$$\Gamma(\alpha) = \int_0^{\infty} x^{\alpha-1} e^{-x} dx \quad \text{è stata introdotta per estendere il fattoriale}$$

$$\Gamma(\alpha) = (\alpha-1)\Gamma(\alpha-1) \quad (\alpha \in \mathbb{R}^+)$$

$$\Gamma(n) = (n-1)! \quad (n \in \mathbb{N})$$

Come generare una v.a. (TH di SHIRNOFF)

$$F_X \longrightarrow F_X^{-1}(U) = Y \quad U \sim [0, 1]$$

↓

ha come f di distribuzione F_X

Sia la densità $f(x) = \frac{x^{\alpha-1} e^{-x}}{\Gamma(\alpha)} \mathbb{1}_{[0, \infty)}(x)$

$$X \rightarrow Y = \beta X \quad T(\alpha, \beta)$$

$$X = \frac{Y}{\beta}$$

GAMMA

$$f_Y(y) = \frac{y^{\alpha-1} e^{-y/\beta}}{\beta^{\alpha} \Gamma(\alpha)} \frac{1}{\beta} = \frac{y^{\alpha-1} e^{-y/\beta}}{\beta^{\alpha} \Gamma(\alpha)} \mathbb{1}_{[0, \infty)}(y)$$

$X \rightarrow f_X(x)$ densità

$$Y \rightarrow g(x) \rightarrow g^{-1}(y) = x$$

$$f_Y(y) = ? = f_X(g^{-1}(y)) \left| \frac{dy}{g^{-1}(y)} \right|$$

$$- \alpha = 1 \Rightarrow \exp \frac{-y/\beta}{\beta}$$

$$- \alpha = \frac{n}{2}, \beta = 2 \quad n \in \mathbb{Z}$$

$$\chi_n^2 \sim z_1^2 + z_2^2 + \dots + z_n^2 \quad z_1, \dots, z_n \stackrel{i.i.d.}{\sim} N(0, 1)$$

STIMIAMO α e β CON I METODI DEI MOMENTI

$$\begin{pmatrix} \alpha \\ \beta \end{pmatrix} = \begin{pmatrix} g_1(\mu_1, \mu_2) \\ g_2(\mu_1, \mu_2) \end{pmatrix}$$

$$\textcircled{1} \quad \mu_1 = \mu_1(\alpha, \beta)$$

LERCO $\gamma' \in \text{Poi INVERTO}$

$$\mu_2 = \mu_2(\alpha, \beta)$$

$$\Rightarrow \mu_1(\alpha, \beta) = \int_0^{\infty} y \frac{y^{\alpha-1} e^{-y/\beta}}{\beta^{\alpha} \Gamma(\alpha)} dy$$

$$= \int_0^{\infty} \frac{y^{\alpha} e^{-y/\beta}}{\beta^{\alpha} \Gamma(\alpha)} dy$$

11 (PERCHÉ)

$$= \frac{\beta \Gamma(\alpha+1)}{\Gamma(\alpha)} \int_0^{\infty} \frac{y^{\alpha} e^{-y/\beta}}{\beta^{\alpha+1} \Gamma(\alpha+1)} dy$$

$$\Gamma(\alpha) = (\alpha-1) \Gamma(\alpha-1)$$

$$\Rightarrow \alpha \beta$$

$$\mu_2(\alpha, \beta) = \int_0^{\infty} y^2 \frac{y^{\alpha-1} e^{-y/\beta}}{\Gamma(\alpha) \cdot \beta^{\alpha}} dy$$

COME PRIMA

$$\downarrow \int_0^{\infty} \frac{y^{\alpha+1} e^{-y/\beta}}{\beta^{\alpha} \Gamma(\alpha)} dy = \frac{\beta^2 \Gamma(\alpha+2)}{\Gamma(\alpha)} \int_0^{\infty} \frac{y^{\alpha+1} e^{-y/\beta}}{\Gamma(\alpha+2) \beta^{\alpha+2}} dy$$

$$\Gamma(\alpha) = (\alpha-1) \Gamma(\alpha-1) \Rightarrow \beta^2 \alpha (\alpha+1)$$

$$\mu_2 - \mu_1^2 = \text{VAR}(\mathcal{T}(\alpha, \beta)) = \beta^2 \alpha^2 + \beta^2 \alpha - (\beta \alpha)^2 = \alpha \beta^2$$

$$\begin{pmatrix} \alpha \\ \beta \end{pmatrix} = \begin{pmatrix} g(\mu_1, \mu_2) \\ \mathcal{G}(\mu_1, \mu_2) \end{pmatrix} = \begin{pmatrix} \frac{\mu_1^2}{\mu_2 - \mu_1} \\ \frac{\mu_2 - \mu_1^2}{\mu_1} \end{pmatrix}$$

$$\alpha = \frac{\alpha^2 \beta^2}{\alpha \beta^2} = \frac{\mu_1^2}{\mu_2 - \mu_1}$$

$$\beta = \frac{\mu_2 - \mu_1^2}{\mu_1} = \frac{\alpha \beta^2}{\alpha \beta}$$

$$\hat{\mu}_1 = \frac{1}{n} \sum_{i=1}^n X_i \quad \Rightarrow \quad \begin{pmatrix} \alpha \\ \beta \end{pmatrix} = \begin{pmatrix} \frac{\hat{\mu}_1^2}{\hat{\mu}_2 - \hat{\mu}_1} \\ \frac{\hat{\mu}_2 - \hat{\mu}_1^2}{\hat{\mu}_1} \end{pmatrix} \quad \text{STIMATORE}$$

$$\hat{\mu}_2 = \frac{1}{n} \sum_{i=1}^n X_i^2$$

È CONSISTENTE?

IN TUTTI I MODI
(ANCHE LGN DI BOREL)

È AS. GAUSSIANA?

NOTA: CI SONO TUTTI
I MOMENTI FINITI
ANCHE y^{1000}
PERCHÉ INTEGRABILE

MOMENTI 2P ✓
E DIFF ✓

JACOBIANO $\begin{pmatrix} \frac{x_1^2}{x_2 - x_1^2} \\ \frac{x_2 - x_1^2}{x_1} \end{pmatrix}$ derivate parziali $\rightarrow$

ES 2

$$X_i \sim \text{Bin}(K, p)$$

$$E[X_i] = Kp = \mu_1$$

$$E[X_i^2] = Kp(1-p) + K^2 p^2 = \mu_2 = Kp - Kp^2 + K^2 p^2$$

$$\text{VAR}(X_i) = \mu_2 - \mu_1^2$$

$$K = \frac{K^2 p^2}{Kp^2} = \frac{\mu_1^2}{\mu_2 - \mu_1^2 + \mu_1^2}$$

$X_i \sim \text{i.i.d}$ momenti finiti

$$p = \frac{\mu_1}{K}$$

È CONSISTENTE PER TUTTE LE LGN (BOREL)

È ASS. GAUSSIANA - -

ES 3

MASSIMA VEROSIMILIANZA

$$X_1, \dots, X_n \sim \text{Poisson}(\lambda)$$

$$\sum_{k=0,1,\dots} \frac{\lambda^k}{k!} \longrightarrow L(\lambda: X_1, \dots, X_n) = \prod_{i=1}^n \frac{e^{-\lambda} \lambda^{X_i}}{X_i!}$$
$$= \frac{e^{-n\lambda} \lambda^{\sum X_i}}{\prod_{i=1}^n X_i!}$$

$$\log L = -n\lambda + \sum X_i \log \lambda - \underbrace{\sum_{i=1}^n \log(X_i!)}$$

f. punteggio

NON SERVE PERCHÉ
COSTANTE

$$\frac{d \log L(\lambda)}{d\lambda} = -n + \frac{\sum X_i}{\lambda}$$

$$\left[\frac{d \log L}{d\lambda} \right]_{\lambda = \lambda_0} = -n + \frac{n \lambda_0}{\lambda} \Big|_{\lambda = \lambda_0} = 0$$

VERO VALORE

$$\hat{\lambda}_{MLE} = \frac{\sum_{i=1}^n X_i}{n}$$

$$\frac{\partial^2 \log l}{\partial^2 \lambda} = - \frac{\sum X_i}{\lambda^2}$$

$$\underbrace{E \left[\frac{\partial^2 \log l}{\partial^2 \lambda} \right]}_{\text{information}} = - \frac{n \lambda_0}{\lambda^2} \Big|_{\lambda = \lambda_0} = - \frac{n}{\lambda_0}$$

informazione

PER I TH DELLA LEZIONE PRECEDENTE

$$\sqrt{n}(\hat{\lambda}_{MLE} - \lambda_0) \longrightarrow N(0, \lambda_0) \quad \left(\frac{-I_1(\theta_0)}{p=1} \right)$$

n sta qui, una sola osservazione

PERCHÉ $\sqrt{n}$?

$$\frac{\hat{\lambda}_{MLE} - \lambda_0}{\sqrt{\frac{\lambda_0}{n}}} \longrightarrow N(0, 1)$$

POICHÉ LA VAR È UN OPERATORE QUADRATICO

AL QC: $E_1 = 1 \quad p = \frac{1}{2}$

(PLOT)


$$X_n =$$

$$= -1 \quad \frac{1}{\sqrt{n}} \sum_{i=1}^n \epsilon_i$$

$$p = \frac{1}{2}$$

— tutte oscillazioni

$$\frac{1}{\sqrt{n}} (L(n)) \rightarrow 0$$



GAUSSIANA $\leftarrow \frac{1}{\sqrt{n}} (TLC)$

ES 2

$$x_1, \dots, x_n \sim \mathcal{N}(\mu, \sigma^2) \rightarrow (\mu, \sigma) \text{ A CASA}$$

$$L(\mu, \sigma^2; x_1, \dots, x_n) = \frac{1}{(2\pi)^{n/2}} \frac{1}{(\sigma^2)^{n/2}} e^{-\frac{1}{2} \sum_{i=1}^n \frac{(x_i - \mu)^2}{\sigma^2}}$$

$$\log L = -\frac{n}{2} \log 2\pi - \frac{n}{2} \log \sigma^2 - \frac{1}{2} \sum_{i=1}^n \left(\frac{x_i - \mu}{\sigma} \right)^2$$

∇L e punteggio

$$\begin{pmatrix} \frac{\partial \log L}{\partial \mu} \\ \frac{\partial \log L}{\partial \sigma^2} \end{pmatrix} = \begin{pmatrix} \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) \\ -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - \mu)^2 \end{pmatrix}$$

il valore medio di questa e vettore di calcolo in μ_0 e σ_0^2 ^{valori veri}

$$E = \begin{pmatrix} \frac{1}{\sigma^2} \sum_{i=1}^n (\mu_0 - \mu) \Big|_{\mu=\mu_0} = 0 \\ -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n E(x_i - \mu)^2 \Big|_{\mu=\mu_0} = 0 \end{pmatrix} \text{ fa } 0$$

DA RIVEDERE

$$J(\mu, \sigma^2) = \begin{pmatrix} -\frac{n}{\sigma^2} & -\frac{1}{\sigma^4} \sum_{i=1}^n x_i y_i \\ -\frac{1}{\sigma^4} \sum_{i=1}^n x_i y_i & \frac{n}{2\sigma^4} - \frac{1}{\sigma^6} \sum_{i=1}^n x_i^2 y_i^2 \end{pmatrix}$$

MISTA

Se gli cambio segno esce la matrice di VAR/cov
e applico il VALORE MEDIO

$$E[H]_{\substack{\mu=\mu_0 \\ \sigma^2=\sigma_0^2}} = \begin{pmatrix} \frac{n}{\sigma_0^2} & 0 \\ 0 & -\frac{n}{2\sigma_0^4} + \frac{n\sigma_0^2}{\sigma_0^6} \end{pmatrix} = \begin{pmatrix} \frac{n}{\sigma_0^2} & 0 \\ 0 & \frac{n}{2\sigma_0^4} \end{pmatrix}$$

M di informazioni

$$\sqrt{n} \begin{pmatrix} \hat{\mu}_{MLE} - \mu_0 \\ \hat{\sigma}_{MLE}^2 - \sigma_0^2 \end{pmatrix} \xrightarrow{d} N \left(\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} \sigma_0^2 & 0 \\ 0 & 2\sigma_0^2 \end{pmatrix} \right)$$

17/11

EFFICIENZA DELLA VEROSIMIGLIANZA

DEF: STIMATORI "BUE" — BEST UNBIASED
vero valore "UMVUE" — UNIFORMLY

$$E[T_n] = \theta_0$$

$$\forall T_n' : E[T_n'] = \theta_0$$

$$\Rightarrow \text{VAR}(T_n) \leq \text{VAR}(T_n')$$

LEMMA ($p=1$)

Se ESISTE "BUE", ALLORA È UNICO.

Dim (PER ASSURDO)

$$T_n'' = \alpha T_n + (1-\alpha) T_n' \quad (\alpha \in [0,1])$$

(combinazione complessa)

DUE STIMATORI NON DISTINTI

LA CONTRADDIZIONE È: $\text{VAR}(T_n'') < \text{VAR}(T_n') = \text{VAR}(T_n)$

$$\begin{aligned} \text{VAR}(T_n'') &= \alpha^2 \text{VAR}(T_n) + (1-\alpha)^2 \text{VAR}(T_n') + 2\alpha(1-\alpha) \text{COV}(T_n, T_n') \\ &= \sigma^2 \left(\alpha^2 + (1-\alpha)^2 + 2\alpha(1-\alpha) \text{COV}(T_n, T_n') \right) \end{aligned}$$

Se lo vorrò $\Rightarrow \text{COV}(T_n, T_n') \leq \frac{\text{COV}(T_n, T_n')}{\sqrt{\text{VAR}(T_n) \text{VAR}(T_n')}} \quad \text{(SKW)}$

Per Hip, T_n e T_n' hanno la stessa varianza ed è minima.

$$\leq \sigma^2 \left(\alpha^2 + (1-\alpha)^2 + 2\alpha(1-\alpha) \frac{\text{Cov}(T_n, T_n')}{\sqrt{\text{VAR}(T_n)\text{VAR}(T_n')}} \right)$$

per non avere assurdo, imporre α

Se per assurdo, fosse $< 1 \Rightarrow$

possiamo trovare T_n'' migliore di T_n e T_n'

$\Rightarrow$ lo stimatore ottimo SE ESISTE, È UNICO!

SE $p > 1$? VAR $\Rightarrow$ MATRICE VAR-COV
 COV
 $A \succeq B \Leftrightarrow A - B \succeq 0$
 (È DEFINITA POSITIVA)

QUAL È LA VARIANZA MINIMA?

LIMITE INFERIORE DI CRAMER-RAO

$p = 1$

THM: Sotto CR (condizioni di regolarità)

LA VAR MIN È DATA DALL' INVERSO DELLA MATRICE DI INFO.

$$E(T_n) = \theta \quad \text{VAR}(T_n) \geq \frac{1}{I_n(\theta_0)} = \frac{1}{n \underline{I_1(\theta_0)}}$$

informazione di

una sola osservazione

$\Rightarrow$ solo come $\frac{1}{n}$

In generale

$$\text{VAR}(T_n) \geq \left(\frac{d}{d\theta} \frac{E(T_n)}{I_n(\theta_0)} \right)^2 \bigg|_{\theta=\theta_0}$$

RICHIAMO: SOTTO (CR) $p=1$

$$\sqrt{n}(\hat{\theta}_{MLE} - \theta_0) \rightarrow_d N(0, I^{-1}(\theta_0))$$

(Dim)

$$\text{COV}^2(X, Y) \leq \text{VAR}(X) \text{VAR}(Y)$$

$$\Rightarrow \text{VAR}(Y) \geq \frac{\text{COV}^2(X, Y)}{\text{VAR}(X)}$$

$$Y = T_n$$

$$\Rightarrow \text{VAR}(Y) = \text{VAR}(T_n)$$

Fx punteggio

$$X = \frac{d}{d\theta} \log L_n(\theta; X_1, \dots, X_n) = S_n(\theta; X_1, \dots, X_n)$$

$$E(S_n(\theta; X_1, \dots, X_n) | \theta = \theta_0) = 0$$

$$E(S_n^2(\theta; X_1, \dots, X_n) | \theta = \theta_0) = I_n(\theta_0) = -E\left[\frac{d^2 \log L}{d\theta^2}\right]$$

MATRICE DI INFORMAZIONE

$$\text{VAR}(T_n) \geq \frac{\text{COV}^2(T_n, S_n)}{I_n(\theta)}$$

RESTA DA DIMOSTRARE

$$\frac{\partial}{\partial \theta} E[T_n] = \text{COV}(T_n, S_n) = E(T_n \cdot S_n)$$

In generale: $\text{COV}(X, Y) = \text{COV}(X) \text{COV}(Y)$?

$$= \frac{\partial}{\partial \theta} \int T(x_1, \dots, x_n) f(x_1, \dots, x_n; \theta) dx_1, \dots, dx_n$$

$$= \int T(x_1, \dots, x_n) \frac{\partial}{\partial \theta} \underbrace{f(x_1, \dots, x_n)}_{f(x_1, \dots, x_n)} dx_1, \dots, dx_n$$

$$= \int_{\mathbb{R}^n} T(x_1, \dots, x_n) \left[\frac{\partial}{\partial \theta} \frac{f(x_1, \dots, x_n; \theta)}{f(x_1, \dots, x_n; \theta)} \right] f(x_1, \dots, x_n; \theta) dx_1, \dots, dx_n$$

→ f punteggio S_n

derivato dello $\log L$

$$\frac{\partial}{\partial \theta} \log(f(x_1, \dots, x_n; \theta))$$

$$= \text{COV}(T_n, S_n)$$

PER CONTINUO, VERBARE QUADERNO

LEZ 19/11

TH (HALMOS-SAVAGE) (FATTORIZZAZIONE)

$$X_1, \dots, X_n \sim f(\cdot, \theta) \quad (\Omega, \mathcal{F}, \mathbb{P}_\theta)$$

$T = T_n(X_1, \dots, X_n)$ è stat. sufficiente

$\Leftrightarrow \exists$ fattorizzazione

$$f(X_1, \dots, X_n; \theta) = h(X_1, \dots, X_n) g(T, \theta)$$

$$T = T(X_1, \dots, X_n; \theta)$$

DIM (CASO DISCRETO)

$\Rightarrow$
 T statistica sufficiente

$$f(X_1, \dots, X_n; T) = \frac{f(X_1, \dots, X_n; \theta)}{f_T(T; \theta)}$$

$$= h(X_1, \dots, X_n)$$

non dipende da θ per
def di stat. sufficiente

$$= f_T(T; \theta) h(X_1, \dots, X_n) \quad \checkmark$$

$$\Leftrightarrow f(x_1, \dots, x_n) = h(x_1, \dots, x_n) \underbrace{q(T; \theta)}$$

f qualsiasi

*non per forza legge di
T, se era legge di
T $\Rightarrow$ dim ovvia*

Non sappiamo com'è q .

Partizioniamo $\mathbb{R}^n$

$$\textcircled{1} A_{T(x_1, \dots, x_n)} \in \mathbb{R}^n := \{y = y_1, \dots, y_n : T(y) = T(x)\}$$


$$\textcircled{2} \frac{f(x_1, \dots, x_n; \theta)}{f_T(T(x_1, \dots, x_n); \theta)} \stackrel{\text{densità di } T}{\in}$$

È IND DA θ ?

$$\begin{aligned} \text{HiP} \\ = \frac{h(x_1, \dots, x_n) q(T, \theta)}{\sum_{y \in A_{T(x)}} h(y_1, \dots, y_n) q(T(y_1, \dots, y_n), \theta)} \end{aligned}$$

*si semplificano per HiP
hanno lo stesso valore*

$x_1 + x_2$ s.s



*Lo stat. s. può
avere 3 valori.*

$$\# \left\{ \sum_{i=1}^n x_i = k \right\} = \binom{n}{k}$$

ESEMPIO

$$X_1, \dots, X_n \sim N(\mu, 1)$$

una s.s. è la media aritmetica

IID

legge congiunta:

$$f(X_1, \dots, X_n; \mu) = \frac{1}{(2\pi)^{n/2}} e^{-\frac{1}{2} \sum_{i=1}^n (X_i - \mu)^2}$$

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

bisogna scriverlo come prodotto tra un f dipendente da $\bar{X}_n$ e una da μ

$$= \frac{1}{(2\pi)^{n/2}} e^{-\frac{1}{2} \sum_{i=1}^n (X_i - \bar{X}_n + \bar{X}_n - \mu)^2}$$

$$= \frac{1}{(2\pi)^{n/2}} e^{-\frac{1}{2} \left[\sum_{i=1}^n (X_i - \bar{X}_n)^2 + n(\bar{X}_n - \mu)^2 \right] - 2 \sum_{i=1}^n (X_i - \bar{X}_n)(\bar{X}_n - \mu)}$$

$$= \frac{1}{(2\pi)^{n/2}} e^{-\frac{1}{2} \sum_{i=1}^n (X_i - \bar{X}_n)^2} \cdot e^{-\frac{1}{2} n(\bar{X}_n - \mu)^2}$$

$\Rightarrow$ è possibile fattorizzare

ESEMPIO FAMIGLIA ESPONENZIALE

$$f(x; \theta) = b_n(x) c(\theta) e^{-\sum_{i=1}^p w_i(\theta) y_i(x)}$$

OBBIETTIVO:

Dimostrare che uno stimatore per essere efficiente deve essere funzione di una statistica sufficiente: $T(n) = \psi(s)$

$$(x|y) \sim f(x, y) \quad E(x) = \int x f_x(x) dx$$

$$E(y) = \int y f_y(y) dy$$

FARE RIPIASSO
DENSITA'

$$f_x(x) = \int f(x, y) dy$$

$$f_{x|y}(x|y) = f_{x|y} = \frac{f_{xy}(x, y)}{f_y(y)}$$

$$E(X|y) = \int x f_{x|y}(x|y) dx$$

$E[X|Y]$ previsione aleatoria

$= E[X|Y(\omega)]$: var aleatoria

$$E_Y[E[X|Y]] = \int \psi(y) f_Y(y) dy = \int \int x \overbrace{f_{X|Y}(x|y) f_Y(y)}^{f_{X,Y}(x,y)} dy$$

TH TORRE

$$E[X|Y] = \int x f_{X|Y}(x|Y(\omega)) d(x)$$
$$= \int x f_X(x) dx = E[X]$$

LEMMA

$(X, Y) \quad E[X], E[Y] < \infty$

$$E[X|Y] = E[X|Y(\cdot)] : \Omega \rightarrow \mathbb{R}$$

$$= \int x f_{X|Y}(x|Y(\cdot)) dx = \psi(Y)$$

LEMMA $E X^2 \quad E Y^2 < \infty$

$$\text{VAR}(X) = \underbrace{\text{VAR}(E(X|Y))}_{\text{incertezza della previsione}} + \underbrace{E(\text{VAR}(X|Y))}_{\text{DATO UN CERTO VALORE QUANTO È INCERTA LA NIA PREVISIONE}}$$

$$0 \leq \frac{\text{VAR}(E(X|Y))}{\text{VAR}(X)} \leq 1 \quad \left. \begin{array}{l} \text{QUANDO SONO VICINI} \\ \text{2 VAR AD ESSERE} \\ \text{1 NA FUNZIONALI TRA LORO} \end{array} \right\}$$

se $X = Y(Y)$

DIM

$$\text{VAR}(X) = E(X - E(X))^2$$

$$= E(X - E(X|Y) + E(X|Y) - E(X))^2$$

$$= E_Y[(E(X - E(X|Y) + E(X|Y) - E(X))^2 | Y)]$$

$$E[\text{VAR}(X|Y)] = E_Y[E(X - E(X|Y))^2 | Y] + E_Y[E(X|Y - E(X))^2 | Y]$$

+ doppio prodotto che fa 0

$$= E[\text{VAR}(X|Y)] + \text{VAR}(E(X|Y))$$

↓
 $\text{VAR}(E(X|Y))$

TH (RAO - BLACKWELL)

$$(\Omega, \mathcal{F}, P_\theta) \quad W = W(X_1, \dots, X_n) \text{ stimatore}$$

$$X_1, \dots, X_n \sim \Pi \quad 1) \quad E W(X_1, \dots, X_n) = \theta_0 \text{ non distorto}$$

$$2) \quad E W^2 < \infty \Rightarrow \text{VAR}(W) < \infty$$

$T \Rightarrow$ stat sufficiente

$$\Rightarrow W' = E[W|T] (= \varphi(T)) \Rightarrow \begin{array}{l} ① \quad E W' = \theta \\ ② \quad \text{VAR}(W') \leq \text{VAR}(W) \end{array}$$

DIM ① $E W' = E_T E[W|T] = E(W)$
TH TORRÈ

$$\begin{aligned} ② \quad \text{VAR}(W) &= \text{VAR}(W') + \\ &= \text{VAR}(E(W|T)) + E(\text{VAR}(W|T)) \\ &\Rightarrow \text{VAR}(W) \geq \text{VAR}(W') \end{aligned}$$

T stat suff serve perche $E(W|T)$ non dipende più da un parametro e lo posso calcolare
↑
giocattolo che è uno stimatore

LEZIONE 24/11

STIMATORI DI BAYES

Ω

Eventi $H_i \in \mathcal{H}$

$$\bigcup_{i=1}^n H_i = \Omega$$

P che E
sia causato da
 H_i

$$H_i \cap H_j = \emptyset \quad \forall i, j = 1, \dots, n \quad i \neq j$$

$E \in \mathcal{E}$ evento osservato

def. p. condizionale

$$P(H_i | E) \stackrel{\checkmark}{=} \frac{P(H_i \cap E)}{P(E)} = \frac{P(E | H_i) P(H_i)}{\sum_{j=1}^n P(E | H_j) P(H_j)}$$

Ω

H_1	H_2	H_3
H_4	H_5	H_6

$P(H_j)$: Probabilità a priori (PRIOR)

$P(E | H_i)$: Verosimiglianza

$P(H_i | E)$: Probabilità a posteriori

I NUMERI DEGLI ESERCIZI SONO SBAGLIATI

(ES 1) TEST PRENATALI

- SINDROME DI DOWN: PER UNA MADRE 30-ENNE

$$P(D) \approx \frac{1}{835}$$

- P. ERRORE FN O FP

$$P(-|D) = \frac{1}{200}$$

$$P(+|D^c) = \frac{1}{200}$$

A NOI INTERESSA $P(D|+)$

$P(\text{DI ESSERE DOWN} \mid \text{ESITO POSITIVO})$
99,9%

$$P(D|+) = \frac{P(+|D)P(D)}{P(+|D)P(D) + P(+|D^c)P(D^c)}$$

$$\begin{aligned} &= \frac{\frac{199}{200} \frac{1}{835}}{\frac{199}{200} \frac{1}{835} + \frac{1}{200} \frac{224}{835}} = \frac{199}{199 + 224} \\ &= 0,47\% \end{aligned}$$

ESEMPIO 2.

60 M

SOLO 60 R

$$P(R | I) \approx \frac{1}{10^6}$$

$$P(I | R) = \frac{1}{60}$$

$$\{\mathcal{R}, \mathcal{I}, P_X \pi(\cdot)\}$$

Non esiste più θ_0 / Θ , bensì una legge $\pi(\cdot)$ sul parametro

$$\pi(\theta | x_1, \dots, x_n) = \frac{f(x_1, \dots, x_n | \theta) \pi(\theta)}{\int f(x_1, \dots, x_n | \theta) \pi(\theta) d\theta}$$

MAP (MAXIMUM APOSTERIORI) (MLE)

$$E[\theta] = \int \theta \pi(\theta | x_1, \dots, x_n) d\theta$$

$$P_v \{ X = k \} = \binom{n}{k} p^k (1-p)^{n-k}$$

VOGLIAMO DARE UNA LEGGE A PRIORI PER P

Def: Legge Beta

$$x \in [0, 1]$$

$$\frac{x^{\alpha-1} (1-x)^{\beta-1}}{\int_0^1 x^{\alpha-1} (1-x)^{\beta-1} dx} = * = B(\alpha, \beta)$$

$$= \frac{\Gamma(\alpha) \Gamma(\beta)}{\Gamma(\alpha + \beta)}$$

$$\text{Quindi: } \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha) \Gamma(\beta)} x^{\alpha-1} (1-x)^{\beta-1}$$

Se $\alpha = \beta = 1 \Rightarrow \text{Uniforme } [0, 1]$

Es: $E[x]$, $\text{VAR}[x]$

$$\frac{\alpha}{\alpha + \beta}$$

$$\frac{\alpha \beta}{(\alpha + \beta)^2 (\alpha + \beta + 1)}$$

DISPENSE 56 + 57

$$\pi(\theta, x_1, \dots, x_n) = \underbrace{\binom{n}{k} p^k (1-p)^{n-k}}_f \underbrace{\frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} p^{\alpha-1} (1-p)^{\beta-1}}_{\pi}$$

$$= \frac{\Gamma(\alpha+\beta+n) p^{k+\alpha-1} (1-p)^{n-k+\beta-1}}{\Gamma(k+\alpha)\Gamma(n-k+\beta)}$$

$$E(p | x_1, \dots, x_n) = \int p \pi(p | x_1, \dots, x_n) dp$$

$$= \frac{k+\alpha}{\alpha+\beta+n} = \underbrace{\left(\frac{k}{n} \cdot \frac{n}{\alpha+\beta+n} \right)}_{\substack{\uparrow \\ \text{MLE}}} \cdot \frac{\alpha}{\alpha+\beta} \cdot \frac{\alpha+\beta}{\alpha+\beta+n}$$

LEZIONE 26/11

Esercizio: $X_1, \dots, X_n \sim N(\mu, 1)$

$$\left. \begin{aligned} \bar{X}_n &= \frac{1}{n} \sum_{i=1}^n X_i \\ \tilde{X}_n &= \sum_{i=1}^n c_i X_i \end{aligned} \right\} \begin{array}{l} \text{QUALE È MIGLIORE?} \\ \text{COME?} \end{array}$$

1) Stat. suff. (risposta più giusta)

2) NO DISTORSIONE $\Rightarrow$

$$E[\tilde{X}_n] = E\left[\sum_{i=1}^n c_i X_i\right] = \sum_{i=1}^n c_i E[X_i] = \mu \sum_{i=1}^n c_i$$

$$\Rightarrow \sum_{i=1}^n c_i = 1$$

Quale valore per c_i ?

$$\min_{c_1, \dots, c_n} \text{VAR}\left(\sum_{i=1}^n c_i X_i\right) \quad \text{s.c.} \quad \sum_{i=1}^n c_i = 1$$

$$= \sum_{i=1}^n c_i^2 \rightarrow \text{Moltiplicatori di Lagrange}$$

$$L(c_1, \dots, c_n) = \sum_{i=1}^n c_i^2 + \lambda (\sum c_i - 1)$$

$\hookrightarrow$ Derivata $\rightarrow \dots$

$$\frac{\partial L}{\partial c_i} = 2c_i + \lambda = 0 \quad \forall i = 1, \dots, n$$

$$c_i = -\frac{\lambda}{2} \Rightarrow c_i \text{ devono essere tutti uguali}$$

$$\Rightarrow \sum c_i = 1 \Rightarrow c_i = \frac{1}{n}$$


$$\frac{\partial L}{\partial \lambda} = \sum c_i - 1 = 0$$

$$\hookrightarrow \bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \quad \text{è il migliore}$$

1) lo stimatore più eff deve dipendere da una stat. sufficiente (minimale)

Oss: Stat. suff. minimale?

Ricordiamo l'esempio



3 casi invece che 4

Somma = 0, 1, 2
dei punti
dovuti

PER RAO - BLACKWELL

$$W = \bar{X}_n = \sum_{i=1}^n c_i X_i \quad \sum_{i=1}^n c_i = 1$$

Se W non distorto, allora, ne posso fare un altro

$$E[W|T] = \phi(T)$$

- non distorto $E[EC(W|\Pi)] = \Theta$
- almeno efficiente $VAR(E(W|\Pi)) \leq VAR(W)$

$$E[\tilde{X}_n | \bar{X}_n]$$

$$\begin{aligned} \frac{1}{(2\pi)^{\frac{n}{2}}} e^{-\frac{1}{2} \sum_{i=1}^n (x_i - \mu)^2} &= \frac{1}{(2\pi)^{\frac{n}{2}}} e^{-\frac{1}{2} \sum_{i=1}^n (x_i - \bar{x}_n + (\bar{x}_n - \mu))^2} \\ &= \frac{1}{(2\pi)^{\frac{n}{2}}} e^{-\frac{1}{2} \sum_{i=1}^n (x_i - \bar{x}_n)^2} \cdot e^{-\frac{n}{2} (\bar{x}_n - \mu)^2} \end{aligned}$$

$$\Rightarrow E[x_i | \bar{x}_n] = \bar{x}_n$$

↑ PERCHÉ NON PUÒ ESSERE μ ?

la legge cond del campione non dipende
(per def di S.S) dal parametro

$$\begin{aligned} \Rightarrow E[\tilde{X}_n | \bar{X}_n] &= \sum_{i=1}^n c_i \overbrace{E[x_i | \bar{x}_n]}^{\bar{x}_n} \\ &= \sum_{i=1}^n c_i \bar{x}_n = \bar{x}_n \end{aligned}$$

ESERCIZIO

$$x_1, \dots, x_n \sim T(\alpha, \beta)$$

1) Verosimiglianza

2) MLE

3) Momenti

4) S.S


5) Prop. Sti

6) Limite inf.

$$L(\alpha, \beta) = \prod_{i=1}^n \frac{x_i^{\alpha-1} e^{-x_i/\beta}}{\Gamma(\alpha) \beta^\alpha} = \frac{\prod_{i=1}^n x_i^{\alpha-1} e^{-\sum \frac{x_i}{\beta}}}{\Gamma(\alpha)^n \beta^{n\alpha}}$$

↳ OSSA: Stat. suff?

$$\text{risposta: } (\sum x_i, \sum \frac{x_i}{\beta}) \quad (\sum \log x_i, \sum x_i)$$

↳ $\log L \leftrightarrow$ MLE di β 

$$\log L = (\alpha - 1) \sum \log x_i - \frac{\sum x_i}{\beta} - n \log \Gamma(\alpha) - n\alpha \log \beta$$

$$\frac{\partial \log L}{\partial \beta} = \frac{\sum x_i}{\beta^2} - \frac{n\alpha}{\beta} \Rightarrow \frac{n\alpha}{\beta} = 0 \rightarrow \text{derivate seconde}$$

$$\hat{\beta}_{MLE} = \frac{\sum x_i}{n\alpha}$$

$$\boxed{E x_i = \alpha \beta}$$

$$\frac{\partial^2 \log L}{\partial^2 \beta} = -2 \frac{\sum x_i}{\beta^3} + \frac{n\alpha}{\beta^2} \quad \text{negative dove } \frac{\partial \log L}{\partial \beta} = 0$$

Prop $\hat{\beta}_{MLE}$? MATRICE INF.

VEDER Funzione GAMMA!

$$E \left[\frac{\partial^2 \log L}{\partial^2 \beta} \right] = E \left[-2 \frac{\sum x_i}{\beta^3} + \frac{n\alpha}{\beta^2} \right] \quad \boxed{E x_i = \alpha \beta}$$

$$= -2 \frac{n\alpha \beta}{\beta^3} + \frac{n\alpha}{\beta^2} = -\frac{n\alpha}{\beta^2}$$

$$I_n(\beta) = -E \frac{\partial^2 \log L}{\partial^2 \beta} = E(S_n^2(\beta)) \Big|_{\beta = \hat{\beta}_{MLE}}$$

↓
punteggio

$$\hookrightarrow \sqrt{n}(\hat{\beta}_{MLE} - \beta_0) \rightarrow_d N(0, \frac{\beta^2}{\alpha})$$

$$\boxed{VAR = I^{-1}}$$

ESE RIZIO

$X_1, \dots, X_n$ IID

$$f(x; \theta) = \frac{\theta}{x^2} \quad x \in [\theta, \infty]$$

$\hookrightarrow$ verificare che è una densità $\Rightarrow$
 $\int \frac{\theta}{x^2} = \frac{1}{\theta} \rightarrow 1$

$\rightarrow \bar{E}$ DISTORTO $EX = \int_{\theta}^{\infty} x \frac{\theta}{x^2} dx = \int_{\theta}^{\infty} \frac{\theta}{x} = \infty$
 $\Rightarrow EX$ infinito

$\rightarrow$ Cond. di Regolarità non valgono

in particolare che si possono scambiare
derivata e integrale, ovvero il supporto
non deve dipendere dal parametro

$\rightarrow$ No metodo dei momenti in quanto devono essere finiti.

$\rightarrow$ No Asintotica Gaussiana per MLE

POSSIAMO CNQ USARE LO STIMATORE

$$L(\theta; x_1, \dots, x_n) = \prod_{i=1}^n \frac{\theta}{x_i^2} \underbrace{1_{[\theta, \infty)}(x_i)}_{\text{perch } x \in (\theta, \infty)}$$

$$= \frac{\theta^n}{\prod_{i=1}^n x_i^2} 1_{[\theta, \infty)}(x_{(1)})$$

il più piccolo
è il continuo

Stat. soft $\Rightarrow$

$$1_{[\theta, \infty)}(x_{(1)})$$

$$\overset{1}{MLE} = \theta^n 1_{[\theta, \infty)}(x_{(1)})$$

$$x \in [0, \theta] \rightarrow \max x_i$$


$$x \in [\theta, \infty) \rightarrow \min x_i$$

$$\theta^n 1_{[\theta, \infty)}(x_{(1)})$$

$\Rightarrow$ NON POSSIAMO DIRE

LE PROP. ASINTOTICHE

$\Rightarrow$ NO TH. LIM. CEN.



ESERCIZIO

$$X_1, \dots, X_n \sim \text{i.i.d.}$$

$$\left. \begin{array}{l} \Theta = 0 \Rightarrow U \sim [0, 1] \\ \Theta = 1 \Rightarrow \frac{1}{2\sqrt{x}} \mathbb{1}_{[0,1]}(x) \end{array} \right\} \begin{array}{l} \text{in entrambi i casi} \\ \text{in } [0, 1] \text{ ma} \\ \text{con leggi diverse} \end{array}$$

Poiché Θ ha soli due valori $\Rightarrow$ NON HA SENSO

PARLARE DI DERIVATE

$$\binom{n}{k} p^k (1-p)^{n-k} \leftarrow \text{LA MLE È IN F. DI } p$$

$\Rightarrow$ derivo rispetto a p ma

non a k (osservazioni)
che sono discrete

$$e^{-x} \frac{x^k}{k!} \xrightarrow{\text{DERIVO PER } x}$$


$$L(\Theta; X_1, \dots, X_n) = \begin{cases} \Theta = 0 \Rightarrow 1 \text{ (caso } U(0,1)) \\ \Theta = 1 \Rightarrow \prod_{i=1}^n \frac{1}{2\sqrt{x_i}} \mathbb{1}_{[0,1]} \end{cases}$$

non è necessario
quando non dipende
dal parametro

$\Rightarrow \hat{MLE} =$ per def di MLE $\Rightarrow$ chi massimizza Θ

$\rightarrow$ per tanti x_i piccoli $\Rightarrow \frac{1}{25} \rightarrow$ GRANDE x_i piccoli!
 $\rightarrow$ piccolo x_i vicino a 1

$\rightarrow$ tanti x_i vicini a 1 $\Rightarrow 1$



ES $x_1, \dots, x_n \sim \text{IB}$

$$F_x = \begin{cases} 0 & x \leq 0 \\ \left(\frac{x}{\beta}\right)^\alpha & 0 \leq x \leq \beta \\ 1 & x > \beta \end{cases}$$

- Sta. Suff

- MLE

+ COMMENTI di qualsiasi tipo

ES

$x_1, \dots, x_n \sim \text{ID}$ $f(x) = \Theta x^{\Theta-1}$ $x \in (0, 1)$
 $x > 0$

- Stat. suff

+ COMMENTI

- MLE

LEGGE $\beta \in \mathbb{R}^+$

$$x^{\alpha-1} (1-x)^{\beta-1}$$

$$B(\alpha, \beta)$$

$$x \in [0, 1]$$

$$B(\alpha, \beta) = \frac{\Gamma(\alpha) \Gamma(\beta)}{\Gamma(\alpha + \beta)}$$

$$\frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha) \Gamma(\beta)} x^{\alpha-1} (1-x)^{\beta-1}$$

$$\Rightarrow E[X] = \int_0^1 \frac{x^{\alpha-1} (1-x)^{\beta-1}}{\Gamma(\alpha) \Gamma(\beta)} \Gamma(\alpha + \beta) dx$$

$$= \int_0^1 x^{\alpha} (1-x)^{\beta-1} dx \cdot \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha) \Gamma(\beta)}$$

$$= \frac{\Gamma(\alpha + 1) \cancel{\Gamma(\beta)}}{\Gamma(\alpha + \beta + 1)} \cdot \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha) \cancel{\Gamma(\beta)}}$$

$$\Gamma(n) = (n-1) \Gamma(n-1)$$

$$= \frac{\alpha}{\alpha + \beta}$$

$$E(x^2) = \frac{\Gamma(\alpha+2) \Gamma(\beta)}{\Gamma(\alpha+\beta+2)} = \frac{\Gamma(\alpha+1) \Gamma(\beta)}{\Gamma(\alpha) \Gamma(\beta)} \frac{\alpha}{(\alpha+\beta+1)(\alpha+\beta)}$$

$$\text{VAR}(x) = E(x^2) - (E(x))^2 =$$

LEZIONE 1/12/25

REGRESSIONE / MODELLO LINEARE


(y_i, x_i) coppie di oss e tra queste
 $i=1, \dots, n$ coppie ci sono delle relazioni

lineari: $y_i = \beta x_i + \varepsilon_i$

↓
peso

↓
distanza

↓
errore



dove $\varepsilon_i \sim \text{i.i.d. } N(0, \sigma_\varepsilon^2)$

stimare una retta
che passi più vicino
ai punti $\Rightarrow$ valore
di β che minimizza
 d

COME MINIMIZZO β ?

$\rightarrow$ MINIMIZZO SCARTI QUADRATI DS

$$\hat{\beta}_{\text{OLS}} = \underset{\beta}{\text{argmin}} \sum_{i=1}^n (y_i - \beta x_i)^2 = \varphi(\beta)$$

$$\frac{d \ell(\beta)}{d\beta} = -2 \sum_{i=1}^n (y_i - \beta x_i) x_i = 0$$

$$\Leftrightarrow \sum_{i=1}^n y_i x_i = \hat{\beta} \sum x_i^2$$

$$\Leftrightarrow \hat{\beta}_{OLS} = \frac{\sum x_i y_i}{\sum x_i^2}$$

$$\frac{d^2 \ell(\beta)}{d\beta^2} = 2 \sum_{i=1}^n x_i^2 > 0 \rightarrow \text{torna perché}$$

sto cercando un
minimo.

PERCHÉ NON USARE LA VEROSIMIGLIANZA?

$$(y_i - \beta x_i) \sim N(0, \sigma_\varepsilon^2)$$

$$L(\beta; y_1, x_1, \dots, y_n, x_n) = \frac{1}{(2\pi)^{n/2}} e^{-\frac{1}{2\sigma_\varepsilon^2} \sum_{i=1}^n (y_i - \beta x_i)^2}$$

$$\log L = -\frac{n}{2} \log 2\pi - \frac{n}{2} \log \sigma_\varepsilon^2 - \frac{1}{2\sigma_\varepsilon^2} \sum_{i=1}^n (y_i - x_i \beta)^2$$

$$\frac{\partial \log l}{\partial \beta} = + \frac{1}{2\sigma_\varepsilon^2} \sum_{i=1}^n (y_i - x_i \beta) x_i$$

$$\hat{\beta}_{MLE} = \hat{\beta}_{OLS}$$

DAL PUNTO DI VISTA GEOMETRICO

$$\begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix} \quad \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix}$$

$$\text{PROJ}(y) \Rightarrow \text{SPAN}(x)$$

$$\hat{\beta} = \frac{\langle x, y \rangle}{\langle x, x \rangle}$$

$$\frac{\langle x, y \rangle}{\langle x, x \rangle}$$

COEFF
di
PROIEZIONE

$$= \frac{\sum x_i y_i}{\sum x_i^2}$$

$$y_i = \beta x_i + \varepsilon_i \rightarrow \beta = \frac{\sum x_i y_i}{\sum x_i^2}$$

$$x_i = \gamma y_i + \varepsilon_i \rightarrow \gamma = \frac{\sum y_i x_i}{\sum y_i^2} \neq \frac{1}{\beta}$$

MODELLO NON LINEARE

$$i=1, \dots, n$$

$$y_i = \beta_1 x_{1i} + \beta_2 x_{2i} + \dots + \beta_k x_{ki} + \varepsilon_i$$

$$Y = X \beta + \varepsilon \quad \varepsilon \sim N(0, \sigma_\varepsilon^2 I_n)$$

$n \times 1$ $n \times k$ $k \times 1$ $n \times 1$

IPOTESI !!!

DA STIMARE

① $k < n$

② $P_Y(X) = K$] proiettore sullo SPAN di X

$$L(\beta, \sigma_\varepsilon^2; Y; X) = \frac{1}{(2\pi\sigma_\varepsilon^2)^{n/2}} e^{-\frac{1}{2\sigma_\varepsilon^2} (Y - X\beta, Y - X\beta)}$$

$k \times 1$ σ_ε^2 $n \times 1$ $n \times k$

↳ la densità di un vettore Gaussiano

$$\frac{1}{(n\sigma_\varepsilon^2)^{n/2}} e^{-\frac{1}{2\sigma_\varepsilon^2} \sum_{i=1}^n \varepsilon_i^2} = \langle \varepsilon, \varepsilon \rangle = \|\varepsilon\|^2$$

per noi $\varepsilon = Y - X\beta$

p. scalare

$$= \log l = -\frac{n}{2} \log 2\pi - \frac{n}{2} \log \sigma_\varepsilon^2 - \frac{1}{2\sigma_\varepsilon^2} (Y - X\beta)^T (Y - X\beta)$$

$1 \times n$ $n \times 1$

dove $(y - X\beta)^T (y - X\beta) = \bar{e}$

$$y^T y - \underbrace{y^T X\beta + \beta^T X^T y}_{-2y^T X\beta} + \beta^T X^T X \beta \quad *$$

ORA FACCIAMO IL GRADIENTE ∇_{β}

$$\nabla_{\beta} * = -2 \underbrace{X^T y}_{\substack{k \times n \quad n \times 1 \\ \downarrow \\ k \times 1}} + 2 \underbrace{(X^T X)}_{k \times k} \beta_{k \times 1}$$

$$\hat{\beta} = (X^T X)^{-1} X^T y$$

$$\rightarrow \hat{y} = X \hat{\beta} = \underbrace{X (X^T X)^{-1} X^T}_{\substack{\text{operatore di} \\ \text{proiezione}}} y$$

Quindi $\hat{\beta}_{MLE} = (X^T X)^{-1} X^T y$
 $\begin{matrix} & & K \times K & & K \times n & & n \times 1 \end{matrix}$

e la previsione $\hat{y} = P_X y = X(X^T X)^{-1} X^T y$

Es: ① fare l'Hessiano e vedere la matrice di info.

② $\hat{\sigma}_{MLE}^2$

$$D_{\sigma^2} \left(-\frac{n}{2} \log 2\pi - \frac{n}{2} \log \sigma_\varepsilon^2 - \frac{1}{2\sigma_\varepsilon^2} (y - X\hat{\beta})^T (y - X\hat{\beta}) \right)$$

$$= -\frac{n}{2\sigma_\varepsilon^2} + \frac{1}{2\sigma_\varepsilon^4} (y - X\hat{\beta})^T (y - X\hat{\beta})$$

$$\Rightarrow \sigma_\varepsilon^2 = \frac{1}{n} \underbrace{(y - X\hat{\beta})^T (y - X\hat{\beta})}_{\text{scarti stimati al quadrato}}$$

$$\begin{aligned} \hat{\varepsilon} &= y - X\hat{\beta} \\ &= y - \underbrace{P_X}_{\text{Op. di proiezione}} y = (I - P_X) y \end{aligned}$$

È VERO CHE VERAMENTE SONO OP. DI PROIEZIONE?

Richiamo:

Un operatore di proiezione deve essere:

1) IDEMPOTENTE

$$P_x^2 = P \Rightarrow P_x = x(x^T x)^{-1} x^T x(x^T x)^{-1} x^T$$

2) SIMMETRICO

$$P_x = P_x^T$$

$$P_x = x(x^T x)^{-1} x^T = (x(x^T x)^{-1} x^T)^T$$

$$I^2 = (I - P_x)^2 = I - P_x - P_x + \underbrace{P_x^2}_{P_x} = I - P_x$$

OSS P_x è una matrice $n \times n$

$$\text{Rg}(P_x) = K$$

Dim: P_x è simmetrica, reale e diag.

$$P_x = Q \Lambda Q^T$$

$\lambda_1, \dots, \lambda_n$ sono pos, reali e tra 0 e 1

$$P_x = Q \Lambda Q^T Q \Lambda Q^T = Q \Lambda^2 Q^T$$

↓

$$\Lambda = \Lambda^2 \Leftrightarrow$$

gli autovalori sono

$$k=1, \quad n-k=0$$

$$\text{Tr}(P_x) = \text{Tr}(X(X^T X)^{-1} X^T) = \text{Tr}(I_k) = k.$$

$$\text{Tr}(AB) = \text{Tr}(BA)$$

$$\text{rg}(M) = n-k$$

$$\text{Tr}(M) = n-k$$

Quindi:

$$\hat{\beta} = (X^T X)^{-1} X^T y$$

$$\hat{\sigma}^2 = \frac{(y - X\hat{\beta})^T (y - X\hat{\beta})}{n}$$

$$\frac{\sum \varepsilon^2}{n} //$$

① Come si comporta
 $\hat{\beta} \rightarrow \text{IE, Dist, } \sigma$

② Come si dis.

σ^2 (dimentica n)

LEZIONE 3/12

Soluzione DOMANDA ①

$$y = X\beta + \varepsilon \quad \varepsilon \sim N(0, \sigma_\varepsilon^2 I_n)$$

$$\begin{aligned}\hat{\beta}_{ML} &= (X^T X)^{-1} X^T y = (X^T X)^{-1} X^T (X\beta + \varepsilon) \\ &= \beta + (X^T X)^{-1} X^T \varepsilon\end{aligned}$$

$\Rightarrow \hat{\beta}_{ML}$ è un vettore gaussiano
perché è una trasformazione
lineare di una gaussiana
(QUALCHE PROP)

$$E[\hat{\beta}_{ML}] = E[\beta] + \underbrace{E[(X^T X)^{-1} X^T \varepsilon]}_{=0} = \beta$$

$$\begin{aligned}E[\underbrace{(\hat{\beta}_{ML} - \beta)_{K \times 1} (\hat{\beta}_{ML} - \beta)^T_{1 \times K}}_{\text{Matrice VAR COV}}] &= E[(X^T X)^{-1} X^T \varepsilon \varepsilon^T X (X^T X)^{-1}] \\ &= (X^T X)^{-1} X^T E[\varepsilon \varepsilon^T] X (X^T X)^{-1} \\ &\quad \sigma_\varepsilon^2 I_n\end{aligned}$$

Lemma $\hat{\beta}_{ML} \sim N(\beta, \sigma_\varepsilon^2 (X^T X)^{-1})$

ES: PER $\text{VAR}(\hat{\beta}_{ML})$ calcolare Matrice info (derivata seconda)

Soluzione ② σ_ε^2 ?

Oss: $\varepsilon^T \varepsilon = \sum_{i=1}^n \varepsilon_i^2 \sim \sigma_\varepsilon^2 \chi_n^2$

$\downarrow$
 χ^2

si distribuisce come una famiglia di χ^2
in particolare χ_n^2

FARE LA χ^2

$\hat{\varepsilon}^T \hat{\varepsilon}$ norma di questo di chi?

$\hat{\varepsilon} = y - X \hat{\beta} = \left[I - X \overbrace{(X^T X)^{-1} X^T}^{\hat{P}} \right] y =$

$= \left[I - X (X^T X)^{-1} X^T \right] (X\beta + \varepsilon)$


FARE IL CONTO E DEVE
FARE ε

$I - P_X$
 $\downarrow$
com. lin.
di gaussiane

$\downarrow$
gaussiana
proiettata
sulla parte
ortogonale

$E = E(y) - E(X\beta) = 0$
" " $X\beta$

$I - P_X$ simm idempotente



Lemma $\hat{\epsilon} \sim N(0, \sigma_\epsilon^2 (I - P_X))$

$$\begin{aligned} E[I - P_X \epsilon \epsilon^T (I - P_X)^T] &= I - P_X E[\epsilon \epsilon^T] (I - P_X)^T \\ &= \sigma_\epsilon^2 (I - P_X) \end{aligned}$$

$$\hat{\epsilon}^T \hat{\epsilon} \sim \frac{\sigma_\epsilon^2}{n} \chi_{n-k}^2$$

$\epsilon^T \epsilon$ vive in uno spazio n
 $\hat{\epsilon}^T \hat{\epsilon}$ vive in uno spazio $n-k$ } Intuizione

Lemma $\hat{\epsilon}^T \hat{\epsilon} \sim \sigma_\epsilon^2 \chi_{n-k}^2$

Dim: $\begin{matrix} I - P_X &= & M \\ n \times n & & n \times n \end{matrix}$

$\text{rg}(M) = n-k$ sim. idempotente

$\Rightarrow$ Diag $\Rightarrow$ autovalori in $[0, 1]$

$$M = Q \Lambda Q^T$$

$$\begin{bmatrix} \lambda_1 & & \\ & \ddots & \\ & & 0 \end{bmatrix}_{n-k \text{ uni}}$$

$$\hat{\Sigma} = \overbrace{(\mathbf{I} - P_k)^T}^M \Sigma$$

$$\hat{\Sigma}^T \Sigma = (M \Sigma)^T (M \Sigma) = \Sigma^T M \Sigma$$

$$\Sigma^T \underbrace{M M}_{\text{perché idempotente}} \Sigma$$

$= M$ perché idempotente

$$= \overbrace{\Sigma^T}^{\mu^T} Q \Lambda \overbrace{Q^T}^{\mu} \Sigma \leftarrow \text{una rotazione}$$

quindi TUTTE
GAUSSIANE SONO

$$\uparrow \mu^T \Lambda \mu = \sum_{i=1}^{n-k} \mu_i^2 = \chi_{n-k}^2$$

GAUSSIANA CON
Matrice diag.

Cosa succede se lo

svolto? **NIENTE**

È LA STESSA GAUSSIANA

perché? $\Sigma \sim N(0, \mathbf{I})$

$$Q \Sigma \sim N(0, \mathbf{I})$$

$$Q Q^T$$

GENERALE

$$X \sim N(\mu, \Sigma)$$

$$AX \sim N(A\mu, A\Sigma A^T)$$

$$E[(X - \mu)(X - \mu)^T]$$

$$E[A(X - \mu)(X - \mu)^T A^T]$$

Lemma (di COCH RANG)

$$W \underset{p \times 1}{\sim} N \left(W_0, \underset{p \times p}{\Sigma_W} \right) \quad \text{rg}(\Sigma_W) = p$$

$$(W - W_0)^T \underbrace{\Sigma_W^{-1} (W - W_0)} \sim \chi_p^2$$

$$\underline{\text{Dim}}: \left[\Sigma_W^{-1/2} (W - W_0) \right]^T \left[\Sigma_W^{-1/2} (W - W_0) \right]$$

$$(W - W_0)^T (\Sigma^{-1/2})^T (\Sigma^{-1/2}) (W - W_0)$$

$$\Sigma^{-1/2} (W - W_0) \underset{\text{G std}}{\sim} N(0, I_p)$$

$$\sim N \left(0, \underbrace{\Sigma_W^{-1/2} \Sigma_W \Sigma_W^{-1/2}}_{I_p} \right)$$

simmetrica
||

$$\Sigma_W^{-1/2} = Q \Lambda^{-1/2} Q^T$$

$$\Sigma_W^{-1} = Q \Lambda^{-1/2} Q^T Q \Lambda^{-1/2} Q^T = Q \Lambda^{-1} Q^T$$

ESEMPIO (TEST)

$y = X\beta + \varepsilon$ con parametri iniziali $\beta = \beta_0$

$$\hat{\beta} \sim N(\beta_0, \underbrace{\sigma_\varepsilon^2 (X^T X)^{-1}}_{\Sigma_\beta})$$

$(\hat{\beta} - \beta_0)^T \Sigma_\beta^{-1} (\hat{\beta} - \beta_0)$ Se le HIP sono vere
allora si deve comportare
come χ_p^2

HIP

$$y = X\beta + \varepsilon \quad \varepsilon \sim N(0, \sigma_\varepsilon^2 I_n)$$

Una HIP più realistica $\varepsilon \sim N(0, \Omega)$ che in
generale non diagonale.
 $\text{rg}(\Omega) = n$

Come stimare β ?

- ① Verosimiglianza $\rightarrow$ bla bla bla
- ② Ricorrersi al caso precedente

Quindi riscrivo come

$$\Omega^{-1/2} y = \Omega^{-1/2} X \beta + \Omega^{-1/2} \varepsilon$$

$$\tilde{y} = \tilde{X} \beta + \tilde{\varepsilon} \quad \tilde{\varepsilon} \sim N(0, I)$$

$$\hat{\beta}_{ML} = \hat{\beta}_{GLS} = (\tilde{X}^T X)^{-1} \tilde{X}^T \tilde{y}$$

$$\downarrow \text{generalized} = (X^T \Omega^{-1} X)^{-1} X^T \Omega^{-1} y$$

COEF IS PROJE IN GEOM. NON
EUCLIDEA.

$$\hat{y} = X \hat{\beta}_{GLS}$$

LEZIONE 10/12

- STIMA PUNTUALE FINO ADESSO
- STIMA PER INTERVALLI
- TEST DELLE IPOTESI

TEST DELLE IPOTESI

Ipotesi: $H_0 : p = p_0$

ipotesi semplice

Ipotesi: $H_0 : p > p_0$

ipotesi composta

$H_1 : p \neq p_0$ oppure $p < p_0$

ipotesi

alternativa

Π : colpevole ma ti assolvo

I : innocente ma ti dichiaro colpevole

	V	F
A	V	I
R	I	V

Ci possono essere

errori: primo tipo / secondo tipo

obiettivo: errore del I tipo $< p$
 $\hookrightarrow \min I, \max II$

SOTTO c. R. $\sqrt{n}(\hat{\theta}_{ML} - \theta_0) \xrightarrow{d} N(0, I'(\theta_0))$
dim 1

- Costruiamo pivot $Z_n = \frac{\sqrt{n}(\hat{\theta}_{ML} - \theta_0)}{\sqrt{I^{-1}(\theta_0)}}$
(deve tendere ad una $N(0,1)$)
 $= \sqrt{n I(\theta_0)} (\hat{\theta}_{ML} - \theta_0)$

- $H_0: \theta = \theta_0$


$\downarrow$
 $N(0,1) \leftarrow \Pr \{ -2 \leq Z_n \leq 2 \} = 95\%$
se trovo $Z_n \geq 2$ e ≤ -2
allora non va bene H_0 .

$(X_1, \dots, X_n) \in \mathbb{R}^n = A \cup R \quad A \cap R = \emptyset$

$A = \{ x_i, i=1, \dots, n : -2 \leq Z_n \leq 2 \}$

$$R = \{X_i : i=1, \dots, n : z_{\alpha/2-1} \cup z_{\alpha/2+1}\}$$

$$P(I_{\text{tipo}}) \leq \alpha$$



VALE LA DISUGUGLIANZA
DI HILL-GORDON

$$P(Z \geq t) \leq \sqrt{\frac{e^{-\frac{t^2}{2}}}{t}}$$

Perche $-2 \leq z_{\alpha/2} \leq 2 = 95\%$
e non un altro che vale 95%

Perche quello simmetrico e quello di
lunghezza minima, a parita di errore
di p di I , massimitto II

Perche l'intervallo simmetrico e quello di
lunghezza minima?

definire una funzione che dipenda dagli estremi di integrazione.

STIMA PER INTERVALLI

$$\frac{\sqrt{n}(\hat{\theta}_{ML} - \theta_0)}{\sqrt{I'(\theta_0)}} \longrightarrow Z_n \sim N(0,1)$$
$$\Downarrow$$

$$Pr \left\{ -z_\alpha \leq \frac{\sqrt{n}(\hat{\theta}_{ML} - \theta_0)}{\sqrt{I'(\theta_0)}} \leq z_\alpha \right\} \approx 1 - \alpha$$

↑
DA VEDERE MEGLIO

$$Pr \left\{ \hat{\theta}_{ML} - z_\alpha \sqrt{\text{VAR}(\hat{\theta}_{ML})} \leq \theta_0 \leq \hat{\theta}_{ML} + z_\alpha \sqrt{\text{VAR}(\hat{\theta}_{ML})} \right\} = 1 - \alpha$$

INTERVALLO CONFIDENZA

Accetti H_0 se Int. conf. comprende H_0 a parità α .

ESEMPIO

IL CAFFÈ PROVOCA TACHICARDIA?

$$\mu_x - \mu_y = 0$$

$$H_0: \mu_x = \mu_y$$

$$X_1, \dots, X_{n_1} \leftarrow \text{beve caffè}$$

$$H_1: \mu_x \neq \mu_y$$

$$Y_1, \dots, Y_{n_2} \leftarrow \text{non beve caffè}$$

$$\text{VAR}(X_1) = \sigma_x^2$$

$$\text{VAR}(Y_1) = \sigma_y^2$$

$$\bar{X}_{n_1} \sim N\left(\mu_x, \frac{\sigma_x^2}{n_1}\right) \rightarrow \frac{\bar{X}_{n_1} - \mu_x}{\sqrt{\frac{\sigma_x^2}{n_1}}} \rightarrow N(0, 1)$$

$$\bar{Y}_{n_2} \sim N\left(\mu_y, \frac{\sigma_y^2}{n_2}\right) \rightarrow \frac{\bar{Y}_{n_2} - \mu_y}{\sqrt{\frac{\sigma_y^2}{n_2}}} \rightarrow N(0, 1)$$

$$\frac{\bar{X}_{n_1} - \bar{Y}_{n_2} - 0}{\sqrt{\frac{\sigma_x^2}{n_1} + \frac{\sigma_y^2}{n_2}}} \rightarrow N(0, 1)$$

vedo quanto viene, scelgo α ...

(VEDERE BENE LA GAUSSIANA)

$$\frac{W_n - EW_n}{\sqrt{\text{VAR}(W_n)}}$$

$$W_n = \bar{X}_n - \bar{Y}_n$$

$$EW_n = \mu_x - \mu_y = 0$$

ESEMPIO

$$H_0: p = p_0$$


↓
0,48

$$n = 1000$$

$$460 \text{ VP}$$

→ FARE I TEST E CALCOLARE INTERVALLO CONFIDENZA

P-VALUE



P: p di area

un numero con

quello o più grande

LEZIONE 15/12

TEST

test su vettore di parametri si può fare con una Gaussiana multivariata ma in pratica si preferisce fare una cosa diversa

$$\underset{p \times 1}{\hat{\beta}} \sim N \left(\underset{p \times 1}{\beta_0}, \underset{p \times p}{\Sigma} \right)$$

↓ STD NORMALIZZARE

$$(\hat{\beta} - \beta_0) \sim N(0, \underset{p \times p}{\Sigma})$$

$$\underset{p \times 1}{\Sigma}^{-1/2} (\hat{\beta} - \beta_0) \sim N(0, I_p)$$

↳ è più comodo trasformarlo in χ^2
norma al quadrato

$$(\hat{\beta} - \beta_0)^T \underbrace{\Sigma^{-1/2} \Sigma^{-1/2}}_{\Sigma^{-1}} (\hat{\beta} - \beta_0) =$$

$$= (\hat{\beta} - \beta_0)^T \bar{\Sigma}^{-1} (\hat{\beta} - \beta_0) \sim \chi^2_p$$

ESEMPIO

$$\underset{n \times 1}{Y} = \underset{n \times n}{X} \underset{k \times 1}{\beta} + \underset{n \times 1}{\varepsilon} \quad \varepsilon \sim N(0, \sigma_\varepsilon^2 I_n)$$

$$H_0: \underset{k \times 1}{\beta} = \underset{k \times 1}{0}$$

① STIMATORE DI β

$$\hat{\beta}_{ML} = (X^T X)^{-1} X^T Y \quad \hat{\beta} \underset{k \times 1}{\sim} N(\beta, \sigma_\varepsilon^2 (X^T X)^{-1})$$

$$\frac{1}{\sqrt{\sigma_\varepsilon^2}} (X^T X)^{1/2} (\hat{\beta} - \beta_0) \sim N(0, I_k)$$

$\downarrow$
 χ^2

Z_k O GUARDO QUI

GAUSSIANA
MULTIVARIATA

$$\|z_k\|^2 = \underset{1 \times k}{z_k^T} \underset{k \times 1}{z_k}$$

$$= \frac{(\hat{\beta} - \beta_0)^T (X^T X) (\hat{\beta} - \beta_0)}{\underbrace{\sqrt{\sigma_\varepsilon^2} \cdot \sqrt{\sigma_\varepsilon^2}}_{\sigma_\varepsilon^2}} \sim \chi_k^2$$

$$\chi_n^2 \sim \mathbb{E} = n$$

$$\chi_n^2 \sim \Gamma\left(\underset{\alpha}{n/2}, \underset{\beta}{2}\right)$$

$$\text{VAR}(\chi_n^2) = 2n$$

$$\chi_n^2 = \sum_{i=1}^n z_i^2$$

$$\chi_n^2 \sim (n, 2n)$$

$$\text{VAR} \rightarrow \sum_{i=1}^n \text{VAR}(z_i^2) = \sum_{i=1}^n \mathbb{E} z_i^4 - (\mathbb{E} z_i^2)^2$$

$$\chi_{100}^2 \sim N(100, 200) =$$

$$\mu \pm \sqrt{200}$$

$$\text{con } P \approx 95\% \Rightarrow 72 - 128$$

$$H_0: \beta = \beta_0 = 0 \Rightarrow \chi^2_k \approx 14 \Rightarrow \text{IPOTESI VERBA}$$

$k = 20$

$$\underset{n \times 1}{Y} = \underset{n \times k}{X} \underset{k \times 1}{\beta} + \varepsilon \quad \boxed{k=n} \quad (g(X) = k=n)$$

$$\hat{y} = y$$

$$\underset{n \times 1}{Y} = \underset{n \times k}{X} \underset{k \times 1}{\beta} + \underset{n \times 1}{\varepsilon}$$

$$H_0: \underset{q \times k}{R} \underset{k \times 1}{\beta} = \underset{q \times 1}{r}$$

$$\hat{\beta}_{ML} = (X^T X)^{-1} X^T y \sim N(\beta, \sigma^2 (X^T X)^{-1})$$

$$\underset{q \times 1}{R\hat{\beta}} \sim N\left(\underset{q \times 1}{r}, \sigma^2 \underset{q \times q}{R(X^T X)^{-1} R^T}\right)$$

$$\frac{(R\hat{\beta} - r)^T (R(x^T x)^{-1} R^T)^{-1} (R\hat{\beta} - r)}{\hat{\sigma}^2} \sim \chi^2_9$$

$(\hat{\sigma}^2)$

se non conosco la varianza
uso lo stimatore $\hat{\sigma}^2$ non cambia
nulla per SLUTZKY

COME CAMBIA SE $\epsilon \sim N(0, \Omega_{n \times n})$

GLS

LEZIONE 17/12

TEST


PIVOT

$$\frac{\hat{\theta}_{ML} - \theta_0}{\sqrt{\text{VAR}(\hat{\theta}_{ML})}} \sim N(0, 1)$$

$$\sum_{p \times 1}^{-1/2} (\hat{\theta}_{ML} - \theta_0) \sim N(0, I_p)$$

TEST DI
WALD

$$(\hat{\theta}_{ML} - \theta_0)^T \sum^{-1/2} (\hat{\theta}_{ML} - \theta_0) \sim \chi_p^2$$



MISURARE LA DISTANZA TRA PARAMETRO
STIMATO ($\hat{\theta}_{ML}$) E VALORE VERO (θ_0)

① MISURARE DIST ORIZZ. $\hat{\theta}_{ML} - \theta_0$ TEST DI WALD


② MISURARE LA DIST VERTICALE TEST LR

$$\log L(\hat{\theta}_{ML}) - \log L(\theta_0)$$

$$= \frac{\log L(\hat{\theta}_{ML})}{L(\theta_0)}$$

QUANTO DIVERSA PIÙ VEROSIMILE

③



verifico quanto lo likelihood è diversa

da 0. (VALORE DEL MOLTIPLICATORE di
Lagrange = valore della derivata)

$\Rightarrow$ QUANTO IL MOLTIPLICATORE di LAGRANGE

IN Θ_0 È DIVERSO DA 0

TEST LM (LAGRANGE MULTIPLIED)

① $\equiv$ ② $\equiv$ ③ ASINTOTICAMENTE SONO EQUIVALENTI

↑

WALD PIÙ INTUITIVO

FINITO!!!

RETI NEURALI

- OSSERVAZIONI Y CHE CERCHI DI
SPIEGARE CON UNA FUNZ.ION $f(X; \Theta) + \varepsilon$
CASO NOSTRO APPROSSIMATO: $X\beta$

ESERCIZI

LUGLIO

$$(1) \Gamma(\alpha, \beta) =$$

$$f_x(\cdot) = \frac{x^{\alpha-1} e^{-x/\beta}}{\Gamma(\alpha) \beta^\alpha} \quad 11(0, \infty)(x)$$

$$(2) E(x), \text{VAR}(x)$$

$$\alpha + \beta$$

$$\alpha \beta^2$$

(FAR VEDERE IL CALCOLO)

$$\int_0^\infty x \frac{x^{\alpha-1} e^{-x/\beta}}{\Gamma(x) \beta^\alpha} dx = E(x)$$

$$\int_0^\infty x^2 \frac{x^{\alpha-1} e^{-x/\beta}}{\Gamma(x) \beta^\alpha} dx = \text{VAR}(x)$$

⑥ f. di Verosimiglianza

$$L(\alpha, \beta) = \frac{\left(\prod_{i=1}^n x_i \right)^{\alpha-1} e^{-\sum x_i / \beta}}{\Gamma(\alpha)^n \beta^n}$$

α sia noto

c) STIMATORE di β

$\log L \rightarrow$ derivata $\rightarrow$ deriva 2°

$\rightarrow$ M di Info

$$\hat{\beta}_{MLE} = \frac{\sum x_i}{n\alpha}$$

d) α sia noto

$\hat{\beta}$ CON MOMENTI

$$E x = \alpha \hat{\beta} = \frac{1}{n} \sum x_i$$

$$\textcircled{2} \quad X_n \quad Y_n \quad X_n = O_p(f_n) \\ Y_n = O_p(g_n)$$

$$\textcircled{a} \quad X_n + Y_n \quad X_n \cdot Y_n \quad X_n \vee^{max} Y_n$$

$$\textcircled{b} \quad X_n + Y_n^2 \quad X_n \cdot Y_n^2 \quad X_n \vee Y_n^2$$

$$X_n + Y_n \cdot Y_n$$

IN CLASSE FATTO
TUTTO

$$\textcircled{3} \quad p = \frac{1}{2} \quad n \text{ lanci}$$

$$\textcircled{a} \quad 0.49 \leq \hat{p}_n \leq 0.51 \quad \text{con } 95\%$$

Stimiamo p .

$$-2 \leq \frac{(\hat{p}_n - \frac{1}{2})}{\sqrt{\frac{1}{4n}}} \leq 2 \quad \text{con } 95\%$$

$$\frac{1}{2} - \gamma \frac{\sqrt{1/n}}{\sqrt{n}} \leq \hat{p}_n \leq \frac{1}{2} + \gamma \frac{\sqrt{1/n}}{\sqrt{n}}$$

QUANTO $n = 10600$

① $0.495 \leq \hat{p}_n \leq 0.505$

QUALE n ?

c) CHE RISULTATO STO USANDO?

ENUNCIATO E DIMOSTRAZIONE

d) DIM CHE $\hat{p}_n \rightarrow \frac{1}{2}$
CON BORELL

$$\textcircled{4} \quad \underset{n \times 1}{Y} = \underset{n \times k}{X} \underset{n \times 1}{\beta} + \underset{n \times 1}{\varepsilon} \quad \varepsilon \sim N(0, \Omega)$$

$$\hat{\varepsilon}^T \Omega^{-1} \hat{\varepsilon} \sim \chi^2_{n-k} \quad \overset{\text{PERCHÉ}}{\hat{\varepsilon}} = Y - X\hat{\beta}_{OLS}$$

a) COME SI DISTRIBUISCE

b) COME USARE QUESTO RISULTATO PER FARE TEST

per verificare il valore di σ_ε^2

$$\frac{\hat{\varepsilon}^T \Omega^{-1} \hat{\varepsilon}}{\sigma_\varepsilon^2} \sim \chi^2_{n-k}$$

che vale se ho messo il valore giusto di σ