

LA REGRESSIONE LINEARE È UNA TECNICA STATISTICA PER MODELLARE LA RELAZIONE TRA UNA VARIABILE DIPENDENTE (y) E UNA O PIÙ VARIABILI INDIPENDENTI (x)

ABBIAMO UN INSIEME DI COPPIE DI OSSERVAZIONI $(y_i, x_i)_{i=1, \dots, n}$ E TRA QUESTE CI SONO DELLE RELAZIONI LINEARI

$$y_i = \beta x_i + \epsilon_i$$


VAR. DIPENDENTE VAR. INDIPENDENTE ERRORE

DOVE $\epsilon_i \sim N(0, \sigma_\epsilon^2)$ I. I. D.

L'OBIETTIVO È STIMARE UNA RETTA CHE PASSI PIÙ VICINO AI PUNTI, OSSIA, TROVARE IL VALORE DI β CHE MINIMIZZA LA DISTANZA d .

COME MINIMIZZARE β ?

IL METODO PIÙ FAMOSO È QUELLO DEI MINIMI QUADRATI ORDINARI (OLS)



$$\hat{\beta}_{ols} = \underset{\beta}{\operatorname{argmin}} \sum_{i=1}^n (y_i - \beta x_i)^2 = \varphi(\beta)$$

$$\frac{d\varphi(\beta)}{d\beta} = -2 \sum_{i=1}^n (y_i - \beta x_i) x_i = 0$$

$$\Leftrightarrow \sum_{i=1}^n y_i x_i = \sum_{i=1}^n \beta x_i^2$$

$$\Leftrightarrow \hat{\beta}_{ols} = \frac{\sum_{i=1}^n y_i x_i}{\sum_{i=1}^n x_i^2}$$

CASO A SINGOLA VARIABILE

$$\dim(\beta) = 1$$

CON LA VEROSIMIGLIANZA?

$$\varepsilon_i \sim N(0, \sigma_\varepsilon^2), \quad y_i = \beta x_i + \varepsilon_i \Rightarrow y_i - \beta x_i = \varepsilon_i \Rightarrow (y_i - \beta x_i) \sim N(0, \sigma_\varepsilon^2)$$

$$L(\beta; y_1, x_1, \dots, y_n, x_n) = \frac{1}{(2\pi\sigma^2)^{n/2}} e^{-\frac{1}{2\sigma_\varepsilon^2} \sum_{i=1}^n (y_i - \beta x_i)^2}$$

$$\log L(\beta; y_1, x_1, \dots, y_n, x_n) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma_\varepsilon^2) - \frac{1}{2\sigma_\varepsilon^2} \sum_{i=1}^n (y_i - \beta x_i)^2$$

$$\frac{d \log L(\beta; y_1, x_1, \dots, y_n, x_n)}{d\beta} = \frac{1}{\sigma_\varepsilon^2} \sum_{i=1}^n (y_i - \beta x_i) x_i = 0$$

$$\Leftrightarrow \sum_{i=1}^n (y_i - \beta x_i) x_i = 0$$

$$\Leftrightarrow \hat{\beta}_{MLE} = \frac{\sum_{i=1}^n y_i x_i}{\sum_{i=1}^n x_i^2}$$

COME POSSIAMO OSSERVARE $\hat{\beta}_{OLS} = \hat{\beta}_{MLE}$

$$\frac{\partial \log L}{\partial \sigma_{\varepsilon}^2} = -\frac{n}{2\sigma_{\varepsilon}^2} + \frac{1}{2\sigma_{\varepsilon}^4} \sum_{i=1}^n (y_i - \hat{\beta}_{ML} x_i)^2 = 0$$

$$\Leftrightarrow -\frac{2\sigma_{\varepsilon}^2}{n} + \frac{2\sigma_{\varepsilon}^4}{\sum_{i=1}^n (y_i - \hat{\beta}_{ML} x_i)^2} = 0$$

$$\Leftrightarrow \sigma_{ML}^2 = \frac{\sum_{i=1}^n (y_i - \hat{\beta}_{ML} x_i)^2}{n}$$

DISTRIBUZIONE DI $\hat{\beta}_{ML}$.

VALOR ATTESO

$$E[\hat{\beta}_{ML}] = E \left[\frac{\sum_{i=1}^n y_i x_i}{\sum_{i=1}^n x_i^2} \right] = \frac{\sum_{i=1}^n x_i E[y_i]}{\sum_{i=1}^n x_i^2} = \beta \frac{\sum_{i=1}^n x_i^2}{\sum_{i=1}^n x_i^2} = \beta$$

$E[y_i] = \beta x_i$

VARIANZA

$$\text{VAR}(Y_i) = \sigma_\varepsilon^2$$

$$\begin{aligned}\text{VAR}[\hat{\beta}_{ML}] &= \text{VAR}\left[\frac{\sum_{i=1}^n Y_i X_i}{\sum_{i=1}^n X_i^2}\right] = \frac{\sum_{i=1}^n \text{VAR}(Y_i X_i)}{\left(\sum_{i=1}^n X_i^2\right)^2} = \frac{\sum_{i=1}^n X_i^2 \text{VAR}(Y_i)}{\left(\sum_{i=1}^n X_i^2\right)^2} \\ &= \frac{\sigma_\varepsilon^2}{\sum_{i=1}^n X_i^2}\end{aligned}$$

DUNQUE $\hat{\beta}_{ML} \sim N\left(\beta, \frac{\sigma_\varepsilon^2}{\sum_{i=1}^n X_i^2}\right)$

OSS: LO STIMATORE $\bar{E}$ NON DISTORTO.

LO STIMATORE $\bar{E}$ CONSISTENTE: $E[\hat{\beta}_{ML}] \xrightarrow{n \rightarrow \infty} \beta$

$$\text{VAR}[\hat{\beta}_{ML}] \xrightarrow{n \rightarrow \infty} 0.$$

DISTRIBUZIONE DI σ_{ML}^2

NOTA: PERCHÉ NON POSSO CALCOLARE DIRETTAMENTE

$$E[\sigma_{ML}^2] = E\left[\frac{1}{n} \sum_{i=1}^n (y_i - \hat{\beta}_{ML} x_i)^2\right] ? \text{ PERCHÉ } y_i \text{ E } \hat{\beta}_{ML} \text{ SONO}$$

DI PENDENTI, E SVOLGENDO IL QUADRATO OTTERREMO IL TERMINE $E[y_i \hat{\beta}_{ML}]$ CHE È MOLTO DIFFICILE DA CALCOLARE

DUNQUE: $\hat{y}_i = \hat{\beta}_{ML} x_i$, QUINDI $\hat{\epsilon}_i = y_i - \hat{y}_i = y_i - \hat{\beta}_{ML} x_i$

$$\text{ALLORA } \sum_{i=1}^n (y_i - \hat{\beta}_{ML} x_i)^2 = \sum_{i=1}^n \hat{\epsilon}_i^2 \Rightarrow \text{SOSTITUIAMO } y_i = \beta x_i + \epsilon_i$$

$$\sigma_{ML}^2 = \frac{RSS}{n} = \frac{\sum_{i=1}^n \hat{\epsilon}_i^2}{n} \sim \chi_n^2$$

$$\begin{aligned} \sum_{i=1}^n (\beta x_i + \epsilon_i - \hat{\beta}_{ML} x_i)^2 &= \sum_{i=1}^n [\epsilon_i - (\hat{\beta}_{ML} - \beta) x_i]^2 \\ &= \sum_{i=1}^n \epsilon_i^2 - (\hat{\beta}_{ML} - \beta)^2 x_i^2 + 2(\hat{\beta}_{ML} - \beta) \epsilon x_i \end{aligned}$$

$$= \sum_{i=1}^n \varepsilon_i^2 - 2(\hat{\beta}_{ML} - \beta) \sum_{i=1}^n \varepsilon_i x_i + (\hat{\beta}_{ML} - \beta)^2 \sum_{i=1}^n x_i^2$$

ORA,
$$\hat{\beta}_{ML} = \frac{\sum_{i=1}^n Y_i X_i}{\sum_{i=1}^n X_i^2} = \frac{\sum_{i=1}^n (\beta X_i + \varepsilon_i) X_i}{\sum_{i=1}^n X_i^2} = \frac{\beta \sum_{i=1}^n X_i^2 + \sum_{i=1}^n \varepsilon_i X_i}{\sum_{i=1}^n X_i^2}$$

$$= \beta + \frac{\sum_{i=1}^n \varepsilon_i X_i}{\sum_{i=1}^n X_i^2} \Rightarrow \hat{\beta}_{ML} - \beta = \frac{\sum_{i=1}^n \varepsilon_i X_i}{\sum_{i=1}^n X_i^2}$$

$$\begin{aligned} = RSS &= \sum_{i=1}^n \varepsilon_i^2 - 2(\hat{\beta}_{ML} - \beta)^2 \sum_{i=1}^n X_i^2 + (\hat{\beta}_{ML} - \beta)^2 \sum_{i=1}^n X_i^2 \\ &= \sum_{i=1}^n \varepsilon_i^2 - 2(\hat{\beta}_{ML} - \beta)^2 \sum_{i=1}^n X_i^2 \end{aligned}$$

USEREMO ORA QUESTA FORMULA PER VALORE ATTESO
E VARIANZA

$$E[\sigma_{ML}^2] = \frac{1}{n} E[RSS] = \frac{1}{n} E\left[\sum_{i=1}^n \varepsilon_i^2 - (\hat{\beta}_{ML} - \beta)^2 \sum_{i=1}^n X_i^2\right]$$

$$= \frac{1}{n} \left(\sum_{i=1}^n E[\varepsilon_i^2] - \sum_{i=1}^n X_i^2 \overbrace{E[(\hat{\beta}_{ML} - \beta)^2]}^{\text{VAR}(\hat{\beta}_{ML})} \right)$$

$$= \frac{1}{n} \left(n \sigma_\varepsilon^2 - \frac{\sigma_\varepsilon^2}{\sum_{i=1}^n X_i^2} \cdot \sum_{i=1}^n X_i^2 \right) = \frac{1}{n} (n \sigma_\varepsilon^2 - \sigma_\varepsilon^2)$$

$$= \left(\frac{n-1}{n} \right) \sigma_\varepsilon^2$$

$$\text{VAR}[\sigma_{ML}^2] = \frac{1}{n^2} \text{VAR} \left[\sum_{i=1}^n \varepsilon_i^2 - (\hat{\beta}_{ML} - \beta)^2 \sum_{i=1}^n X_i^2 \right]$$

$$= \frac{1}{n^2} \sum_{i=1}^n \text{VAR}(\varepsilon_i^2) - \left(\sum_{i=1}^n X_i \right)^2 \text{VAR}(\hat{\beta}_{ML} - \beta)$$

$$= \frac{1}{n^2} (2 n \sigma_{\varepsilon}^4 - 2 \sigma_{\varepsilon}^2) = \frac{2 (n-1) \sigma_{\varepsilon}^4}{n^2}$$

$$\sum \varepsilon_i^2 \sim \chi_1^2$$

$$\sum (\hat{\beta}_M - \beta)^2 \sim \chi^2,$$

$$\text{VAR}(\varepsilon_i^2) = 2 \sigma_{\varepsilon}^4$$

$$\text{VAR}[(\hat{\beta}_M - \beta)^2] = 2 \sigma_{\varepsilon}^4$$

QUINDI, $\sigma_{ML}^2 \sim N \left(\left(\frac{n-1}{n} \right) \sigma_{\varepsilon}^2, \frac{2(n-1) \sigma_{\varepsilon}^4}{n^2} \right)$

MODELLO LINEARE MULTIVARIATO

(y_i, x_i) COPPIE DI OSSERVAZIONI PER CUI VALGA LA SEGUENTE
 $i = 1, \dots, n$ RELAZIONE

$$y_i = x_{1i} \beta_1 + x_{2i} \beta_2 + \dots + x_{ki} \beta_k + \varepsilon_i$$

IN FORMA
MATRICIALE

ERRORE / RESIDUO

$$Y = X\beta + \varepsilon$$

$$\varepsilon \sim N(0, \sigma_\varepsilon^2 I_n)$$

$(y_1, \dots, y_n)^T$
 $n \times 1$

MATRICE $n \times k$

$k \times 1$

VETTORE $n \times 1$
DEI RESIDUI

PRIMA DI PROCEDERE ABBIAMO BISOGNO DI ULTERIORI CONDIZIONI SULLE X

1) LE VARIABILI X SONO DETERMINISTICHE

2) $\text{rg}(X) = K \Rightarrow K \leq n$

QUESTE IPOTESI VENGONO ABBANDONATE NEGLI STUDI PIÙ RECENTI.

PROPOSIZIONE

LO STIMATORE DI VEROSIMIGLIANZA NEL MODELLO MULTIVARIATO HA LA SEGUENTE FORMA:

$$1) \hat{\beta}_{MLE} = (X^T X)^{-1} X^T Y$$

$$2) \hat{\sigma}_{MLE}^2 = \frac{1}{n} (\hat{\varepsilon}^T \hat{\varepsilon})$$

$$\text{DOVE } \hat{\varepsilon} = Y - \hat{Y} = Y - X \hat{\beta}$$

E INOLTRE

$$\begin{aligned} \hat{\beta}_{MLE} &\xrightarrow{d} N(\beta, \sigma_\varepsilon^2 (X^T X)^{-1}) \\ n \frac{\hat{\sigma}_{MLE}^2}{\sigma^2} &\xrightarrow{d} \chi^2_{n-K} \end{aligned}$$

PROOF:

INIZIAMO CON CALCOLARE $\hat{\beta}_{MLE}$.

$$L(\beta, \sigma_\epsilon^2; Y; X) = \frac{1}{(2\pi\sigma_\epsilon^2)^{n/2}} e^{-\frac{1}{2\sigma_\epsilon^2} \langle Y - X\beta, Y - X\beta \rangle}$$

$\langle \epsilon, \epsilon \rangle$ MA
 $\epsilon = Y - X\beta$

→ POICHÉ $\epsilon \sim N(0, \sigma_\epsilon^2 I_n)$, ALLORA LA DENSITA' DI UN VETTORE GAUSSIANO È

$$\frac{1}{(2\pi\sigma_\epsilon^2)^{n/2}} e^{-\frac{1}{2\sigma_\epsilon^2} \sum_{i=1}^n \epsilon_i^2} = \langle \epsilon, \epsilon \rangle = \|\epsilon\|^2$$

PRODOTTO SCALARE

$$\log L = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma_\epsilon^2) - \frac{1}{2\sigma_\epsilon^2} \underbrace{(Y - X\beta)^T}_{1 \times n} \underbrace{(Y - X\beta)}_{n \times 1}$$

$$\begin{aligned} (Y - X\beta)^T (Y - X\beta) &= Y^T Y - Y^T X \beta - \beta^T X^T Y + \beta^T X^T X \beta \\ &= Y^T Y - 2\beta^T X^T Y + \beta^T X^T X \beta \end{aligned}$$

$$\nabla_{\beta} \log L = -\frac{1}{2\sigma_{\varepsilon}^2} (-2X^T Y + 2(X^T X) \beta) = 0$$

$$\Leftrightarrow -2X^T Y + 2(X^T X) \beta = 0$$

$$\Leftrightarrow (X^T X) \beta = X^T Y$$

$$\Leftrightarrow \hat{\beta}_{MLE} = (X^T X)^{-1} X^T Y$$

1) VALORE ATTESO $E[\hat{\beta}_{MLE}]$

$$\hat{\beta}_{MLE} = (X^T X)^{-1} X^T (X\beta + \varepsilon) = \underbrace{(X^T X)^{-1} (X^T X)}_{=I} \beta + (X^T X)^{-1} X^T \varepsilon$$

$$= \beta + (X^T X)^{-1} X^T \varepsilon$$

$$\Rightarrow E[\beta + (X^T X)^{-1} X^T \varepsilon] = E[\beta] + \underbrace{E[(X^T X)^{-1} X^T \varepsilon]}_{=0} = E[\beta] = \beta.$$

QUINDI LO STIMATORE È NON DISTORTO.

2) MATRICE VARIANZA E COVARIANZA

$$E[(\hat{\beta}_{MLE} - \beta)(\hat{\beta}_{MLE} - \beta)^T] = E[(X^T X)^{-1} X^T \varepsilon ((X^T X)^{-1} X^T \varepsilon)^T]$$



$$\hat{\beta}_{ML} = \beta + (X^T X)^{-1} X^T \varepsilon$$

$$\Rightarrow \hat{\beta}_{ML} - \beta = (X^T X)^{-1} X^T \varepsilon$$

$$= E[(X^T X)^{-1} X^T \varepsilon \varepsilon^T X (X^T X)^{-1}] = (X^T X)^{-1} X^T E[\varepsilon \varepsilon^T] X (X^T X)^{-1}$$

$$= (X^T X)^{-1} X^T \sigma_\varepsilon^2 I_n X (X^T X)^{-1} = \sigma_\varepsilon^2 (X^T X)^{-1} X^T X (X^T X)^{-1}$$

$$= \sigma_\varepsilon^2 (X^T X)^{-1}$$

CALCOLIAMO ORA σ_{MLE}^2

$$\log L = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma_\varepsilon^2) - \frac{1}{2\sigma_\varepsilon^2} (y - X\beta)^T (y - X\beta)$$

$$\begin{aligned} (y - X\beta)^T (y - X\beta) &= y^T y - y^T X\beta - \beta^T X^T y + \beta^T X^T X \beta \\ &= y^T y - 2\beta^T X^T y + \beta^T X^T X \beta \end{aligned}$$

$$\nabla_{\sigma_\varepsilon^2} \log L = -\frac{n}{2\sigma_\varepsilon^2} - \frac{1}{2\sigma_\varepsilon^4} (y - X\hat{\beta})^T (y - X\hat{\beta}) = 0$$

$$\Leftrightarrow \frac{-n\sigma_\varepsilon^2 - (y - X\hat{\beta})^T (y - X\hat{\beta})}{2\sigma_\varepsilon^4} = 0$$

$$\Leftrightarrow -n\sigma_\varepsilon^2 - (y - X\hat{\beta})^T (y - X\hat{\beta}) = 0$$

$$\Leftrightarrow \sigma_{MLE}^2 = (y - X\hat{\beta})^T (y - X\hat{\beta}) \cdot \frac{1}{n} = \boxed{\frac{\hat{\varepsilon}^T \hat{\varepsilon}}{n}}$$

PER DIMOSTRARE COME SI DISTRIBUISCE σ_{MLE}^2 È NECESSARIO INTRODURRE ALCUNE NOZIONI AGGIUNTIVE DELL'ALGEBRA LINEARE.

OSS: $E[Y] = E[X\beta + \varepsilon] = E[X\beta] + E[\varepsilon] = X\beta$

DEFINIAMO:

1) $\hat{Y} = X\hat{\beta}$ IL VALORE PREVISTO PER IL VETTORE Y SULLA BASE DELLE STIME $\hat{\beta}$ E DEL VALORE DEI REGRESSORI X .

2) $\hat{\varepsilon} = Y - X\hat{\beta}$ LA STIMA DEL VETTORE DEGLI ERRORI

ABBIAMO QUINDI CHE

$$\hat{Y} = X(X^T X)^{-1} X^T Y = P_X Y \quad \text{DOVE } P_X = X(X^T X)^{-1} X^T \text{ È UNA MATRICE DI PROIEZIONE.}$$

- IDEMPOTENTE $P_X^2 = P_X$

$$P_X^2 = X(X^T X)^{-1} \underbrace{X^T X(X^T X)^{-1}}_{=I} X^T = X(X^T X)^{-1} X^T = P_X$$

NOTA: NON SI PUO' USARE $(AB)^{-1} = B^{-1}A^{-1}$ PERCHÉ X NON È QUADRATA.
INFATTI X È RETTANGOLARE (m RIGHE $\times$ K COLONNE).

$(X^T X)^{-1}$ ESISTE PERCHÉ QUADRATA $K \times K$

- SIMMETRICA $P_X = P_X^T$

$$P_X^T = (X (X^T X)^{-1} X^T)^T = X^T (X^T X)^{-1} X$$



- $(AB)^T = B^T A^T$

- SE A SIMMETRICA $A^T = A$, $(A^{-1})^T = (A^T)^{-1}$

IN PARTICOLARE, L'AZIONE DELLA MATRICE P_X CORRISPONDE A PROIETTARE IL VETTORE Y SULLO SPAZIO VETTORIALE DI DIMENSIONE K GENERATO DALLE COLONNE DI X .

ABBIAMO INOLTRE CHE

$$\hat{\epsilon} = y - x\hat{\beta} = y - x(x^T x)^{-1} x^T y = (I - x(x^T x)^{-1} x^T) y = (I - P_x) y$$

$$\hat{\epsilon} = (I - P_x) y = M_x y \quad \text{DOVE} \quad M_x = I - P_x \quad \text{MATRICE DI PROIEZIONE}$$

- IDEMPOTENTE $M_x^2 = M_x$

$$M_x^2 = (I - P_x)^2 = I^2 - 2IP_x + P_x^2 = I - 2P_x + P_x = I - P_x = M_x$$

- SIMMETRICA $M_x^T = M_x$

$$M_x^T = (I - P_x)^T = I^T - P_x^T = I - P_x = M_x$$

L'AZIONE DI M_X CONSISTE NEL PROIETTARE Y NELLO SPAZIO ORTOGONALE A QUELLO GENERATO DALLE COLONNE DI X .

LEMMA: LE MATRICI P_X E M_X HANNO TUTTI AUTOVALORI PARI A ZERO O UNO.

$$- \operatorname{rg}(P_X) = k$$

$$- \operatorname{rg}(M_X) = n - k$$

PROOF: DI MOSTRIAMO P_X . POICHÉ $\bar{E}$ È SIMMETRICA E REALE, SI PUÒ DIAGONALIZZARE.

$$P_X = Q \Lambda Q^T, \quad \text{DOVE } Q Q^T = Q^T Q = I_n \quad \text{E}$$

$$\Lambda = \begin{pmatrix} \lambda_1 & & & \\ & \lambda_2 & & \\ & & \ddots & \\ 0 & & & \lambda_n \end{pmatrix}$$

Si ha allora $P_x^2 = Q \wedge Q^T Q \wedge Q^T = Q \wedge^2 Q^T = Q \wedge Q^T$ da cui segue che $\lambda_i = 0$ o 1 per $i = 1, \dots, n$.

Per quello che riguarda il rango, notiamo che esso eguaglia il numero di autovalori diversi da 0 (diciamo k).

$$\text{Tr}(P_x) = \text{Tr}(X(X^T X)^{-1} X^T) = \text{Tr}(\underbrace{(X^T X)^{-1}}_{k \times k} \underbrace{X^T X}_{k \times k}) = \text{Tr}(I_k) = k = \text{rg}(P_x)$$

$\downarrow$
 $\text{Tr}(AB) = \text{Tr}(BA)$

Per M_x , anch'essa è diagonalizzabile,

$M_x = Q \wedge Q^T$, e poiché è idempotente,

$$M_x^2 = Q \wedge Q^T Q \wedge Q^T = Q \wedge^2 Q^T = Q \wedge Q^T = M_x, \text{ da cui}$$

segue che $\lambda_i = 0$ o 1 per $i = 1, \dots, n$.

PER IL RANGO, ABBIAMO CHE

$$\text{Tr}(M_x) = \text{Tr}(I_n - P_x) = \text{Tr}(I_n) - \text{Tr}(P_x) = n - k.$$

SIAMO ORA IN GRADO DI DIMOSTRARE IL COMPORTAMENTO

DELLO STIMATORE $\hat{\sigma}_{MLE}^2 = \frac{1}{n} (\hat{\varepsilon}^T \hat{\varepsilon})$

LEMMA: $\hat{\varepsilon}^T \hat{\varepsilon} \sim \chi_{n-k}^2 \Rightarrow n \frac{\hat{\sigma}_{MLE}^2}{\sigma_\varepsilon^2} \xrightarrow{d} \chi_{n-k}^2 \quad (\sigma_{MLE}^2 \sim \sigma_\varepsilon^2 \chi_{n-k}^2)$

PROOF: $\hat{\varepsilon} = Y - X\hat{\beta} = Y - X(X^T X)^{-1} X^T Y = (I - P_x)Y = M_x Y$

SOSTITUIAMO ORA $Y = X\beta + \varepsilon$, OTTENENDO

$$\hat{\varepsilon} = M_x Y = M_x (X\beta + \varepsilon) = \boxed{M_x X} \beta + M_x \varepsilon = M_x \varepsilon$$

= 0 PERCHE M_x PROIETTA NELLO SPAZIO ORTOGONALE A X .

INFATTI: $M_X X = (I - P_X) X = X - P_X X = X - X(X^T X)^{-1} X^T X = X - X = 0$

Quindi,

$(AB)^T = B^T A^T$

M_X SIMMETRICA

$$\hat{\varepsilon}^T \hat{\varepsilon} = (M_X \varepsilon)^T M_X \varepsilon \stackrel{\downarrow}{=} \varepsilon^T M_X^T M_X \varepsilon \stackrel{\downarrow}{=} \varepsilon^T M_X M_X \varepsilon = \varepsilon^T M_X^2 \varepsilon$$

$$= \varepsilon^T M_X \varepsilon$$

M_X IDEMPOTENTE

ORA, POICHÉ $M_X = Q \Lambda Q^T$

$$\hat{\varepsilon}^T \hat{\varepsilon} = \varepsilon^T M_X \varepsilon = \varepsilon^T Q \Lambda Q^T \varepsilon \stackrel{\uparrow}{=} \mu^T \Lambda \mu \stackrel{*}{=} \sum_{i=1}^{n-k} \mu_i^2 = \chi_{n-k}^2$$

SONO VETTORI

* VALE CHE: SE $X \sim N(\mu, \Sigma)$, ALLORA $AX \sim N(A\mu, A\Sigma A^T)$
(X VETTORE, A MATRICE)

INFATTI: $\epsilon \sim N(0, I_n) \Rightarrow Q\epsilon \sim N(0, I_n) = N(0, QIQ^T)$

QUINDI SE HO UN VETTORE STANDARD E LO RUOTO, NON SUCCEDER
NULLA. RIOTTENGO UN'ALTRA GAUSSIANA IDENTICA ALLA PRECEDENTE.

LEMMA DI COACHRANG:

Sia $W \sim N(\underbrace{W_0}_{d \times 1}, \underbrace{\Sigma_W}_{d \times d})$, CON RANGO PIENO, $\text{rg}(W) = d$.

ALLORA

$$(W - W_0)^T \Sigma_W^{-1} (W - W_0) \sim \chi_d^2 \quad *$$

PROOF: POSSIAMO RISCRIVERE * COME

$$\left(\Sigma_W^{-1/2} (W - W_0) \right)^T \left(\Sigma_W^{-1/2} (W - W_0) \right) = (W - W_0)^T (\Sigma_W^{-1/2})^T \Sigma_W^{-1/2} (W - W_0)$$

PER CONCLUDERE LA DIMOSTRAZIONE, RIMANE DA DIMOSTRARE

$$\Sigma_W^{-1/2} (W - W_0) \sim N(0, I_d)$$

$$E\left[\sum_{\omega}^{-1/2} (W - W_0)\right] = \sum_{\omega}^{-1/2} (E[W] - E[W_0]) = \sum_{\omega}^{-1/2} (W_0 - W_0) = 0$$

$$\text{VAR}\left[\sum_{\omega}^{-1/2} (W - W_0)\right] = \sum_{\omega}^{-1/2} \sum_{\omega} \sum_{\omega}^{-1/2} = I_d$$

LO STIMATORE GLS (GENERALIZED LEAST SQUARES)

POSSIAMO GENERALIZZARE OLS, IMMAGINANDO CHE I RESIDUI
 E ABBIANO UNA STRUTTURA DI DIPENDENZA MOLTO PIÙ COMPLESSA
 DI VARIABILI INDIPENDENTI.

POTIZZIAMO $E[\varepsilon \varepsilon^T] = \Omega$ CON MATRICE POSITIVA DEFINITA DI
 RANGO (PIENO) n .

$$L(\beta; Y, X) = \frac{1}{(2\pi)^{n/2}} \frac{1}{\sqrt{\det(\Omega)}} e^{-1/2 (Y - X\beta)^T \Omega^{-1/2} (Y - X\beta)}$$

INVECE DI PROCEDERE NORMALMENTE, SFRUTTIAMO UN PICCOLO TRUCCO.

$\Omega = Q \Lambda_\Omega Q^T$, POSSIAMO QUINDI DEFINIRE $\Omega^{-1/2} = Q \Lambda_\Omega^{-1/2} Q^T$
AVENTE LA PROPRIETÀ CHE

$$\begin{aligned}\Omega^{-1/2} \Omega \Omega^{-1/2} &= Q \Lambda_\Omega^{-1/2} Q^T Q \Lambda_\Omega Q^T Q \Lambda_\Omega^{-1/2} Q^T \\ &= Q \Lambda_\Omega^{-1/2} \Lambda_\Omega \Lambda_\Omega^{-1/2} Q^T \\ &= Q Q^T = I_n\end{aligned}$$

A QUESTO PUNTO, DEFINIAMO $\hat{\beta}_{GLS}$ COME

$$\hat{\beta}_{GLS} = (X^T \Omega^{-1} X)^{-1} X^T \Omega^{-1} Y$$

COEFFICIENTE DI PROIEZIONE IN
GEOMETRIA NON EUCLIDEA