

STATISTICHE SUFFICIENTI

DOMANDA: È POSSIBILE COMPRIMERE UN CAMPIONE DI DATI OSSERVATI SENZA PERDERE INFORMAZIONE SUL PARAMETRO CHE MI INTERESSA?

DEF: UNA STATISTICA $T_n = T(X_1, \dots, X_n)$ SI DICE **SUFFICIENTE** PER IL PARAMETRO θ SE LA DISTRIBUZIONE DEL CAMPIONE CONDIZIONATA A T_n NON DIPENDE DA θ

$T_n = T(X_1, \dots, X_n)$ **STATISTICA SUFFICIENTE**

$\Leftrightarrow$

$$h(X_1, \dots, X_n | T_n)$$

NON DIPENDE DA θ

ABBIAMO QUINDI

$$L(\theta; X_1, \dots, X_n) = f(X_1, \dots, X_n; \theta) = h(X_1, \dots, X_n | T) \cdot q(T; \theta)$$

DALLA DEFINIZIONE DI PROBABILITÀ CONDIZIONATA È IMMEDIATO

VERIFICARE CHE T È SUFFICIENTE SE E SOLO SE

$p(x_1, \dots, x_n; \theta)$ —> LEGGE CONGIUNTA
NON DIPENDE DA θ

$q(T(x_1, \dots, x_n); \theta)$ LA FUNZIONE DI PROBABILITÀ DELLA STATISTICA
SUFFICIENTE T .

ESEMPIO

$X_1, \dots, X_n \sim \text{Ber}(\theta)$ I.I.D.

LA LEGGE CONGIUNTA È DATA DA

$$p(x_1, \dots, x_n; \theta) = \theta^{\sum_{i=1}^n x_i} (1-\theta)^{n - \sum_{i=1}^n x_i}$$

VERIFICHIAMO CHE $T_n = \sum_{i=1}^n X_i$ SIA UNA STATISTICA SUFFICIENTE.

LA SUA FUNZIONE DI PROBABILITÀ È UNA BINOMIALE

$$q(T_n(x_1, \dots, x_n); \theta) = \binom{n}{\sum_{i=1}^n x_i} \theta^{\sum_{i=1}^n x_i} (1-\theta)^{n - \sum_{i=1}^n x_i}$$

QUINDI $\frac{f(x_1, \dots, x_n)}{q(T_n(x_1, \dots, x_n); \theta)} = \frac{1}{\binom{n}{\sum_{i=1}^n x_i}}$

QUINDI,

$$f(x_1, \dots, x_n) = \left(\frac{1}{\binom{n}{\sum_{i=1}^n x_i}} \right) \left(\binom{n}{\sum_{i=1}^n x_i} \theta^{\sum_{i=1}^n x_i} (1-\theta)^{n - \sum_{i=1}^n x_i} \right)$$

$$q(T(x_1, \dots, x_n); \theta)$$

$$h(x_1, \dots, x_n | T)$$

TEOREMA DI FATTORIZZAZIONE DI HALKOS-SAVAGE

UNA STATISTICA È SUFFICIENTE SE E SOLO SE LA FUNZIONE DI PROBABILITÀ (O DENSITÀ) DI $X_1, \dots, X_n$ SI FATTORIZZA COME

$$p(X_1, \dots, X_n; \theta) = g(T(X_1, \dots, X_n); \theta) h(X_1, \dots, X_n)$$

PROOF:

$\Rightarrow$ T È STATISTICA SUFFICIENTE. LA FATTORIZZAZIONE È OVVIA. BASTA PRENDERE $g(T; \theta) = q(T; \theta)$ e h LA LEGGE DELLE X_i CONDIZIONATA A T , CHE SAPPIAMO ESSERE INDIPENDENTE DA θ

$\Leftarrow$ $\exists$ FATTORIZZAZIONE. IN QUESTO CASO LA DIMOSTRAZIONE NON È BANALE IN QUANTO NON È DETTO CHE LA FATTORIZZAZIONE CORRISPONDA ALLA COPPIA (LEGGE DI T , LEGGE DI $X_1, \dots, X_n$ CONDIZIONATA A T).

CASO DISCRETO. PARTIZIONIAMO IL DOMINIO DI $X_1, \dots, X_n$ IN CLASSI DI EQUIVALENZA CORRISPONDENTI AI VALORI DELLA STATISTICA SUFFICIENTE. DEFINIAMO CIOÈ I SOTTOINSIEMI DI $\mathbb{R}^n$ COME

$$A_T(x_1, \dots, x_n) \subseteq \mathbb{R}^n := \{y = y_1, \dots, y_n : T(y) = T(x)\}$$

PRENDIAMO ORA IL RAPPORTO

$$\frac{p(x_1, \dots, x_n; \theta)}{q(T(x_1, \dots, x_n); \theta)} \stackrel{=}{\uparrow} \frac{g(T(x_1, \dots, x_n); \theta) h(x_1, \dots, x_n)}{q(T(x_1, \dots, x_n); \theta)}$$

PER HIP ESISTE
LA FATTORIZZAZIONE

$$= \frac{\cancel{g(T(x_1, \dots, x_n); \theta)} h(x_1, \dots, x_n)}{\sum_{y \in A_T(x)} h(y_1, \dots, y_n) \cancel{g(T(y_1, \dots, y_n); \theta)}}$$

$$= \frac{h(X_1, \dots, X_n)}{\sum_{Y \in A_T(x)} h(Y_1, \dots, Y_n)} \quad \text{CHE NON DIPENDE DA } \theta.$$

ESEMPIO

$$X_1, \dots, X_n \sim N(\mu, 1)$$

LA LEGGE CONGIUNTA È: $f(X_1, \dots, X_n; \theta) = \frac{1}{(2\pi)^{n/2}} e^{-\frac{1}{2} \sum_{i=1}^n (x_i - \mu)^2}$

SE ESPANDIAMO IL QUADRATO, OTTIENIAMO:

$$\sum_{i=1}^n (x_i - \mu)^2 = \sum_{i=1}^n (x_i - \bar{X}_n + \bar{X}_n - \mu)^2 \quad \text{POICHÉ L'ASSUNZIONE È}$$

CHE $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ È UNA S.S., È NECESSARIO SCRIVERE LA LEGGE COME
 PRODOTTO TRA UNA FUNZIONE CHE DIPENDE A $\bar{X}_n$ E UNA DA μ .

$$= \sum_{i=1}^n (X_i - \bar{X}_n)^2 + n(\bar{X}_n - \mu) - 2 \sum_{i=1}^n [(\bar{X}_n - \mu) - (X_i - \bar{X}_n)]$$

$$\Rightarrow f(X_1, \dots, X_n; \theta) = \underbrace{\frac{1}{(2\pi)^{n/2}} e^{-\frac{1}{2} \sum_{i=1}^n (X_i - \bar{X}_n)^2}}_h \cdot \underbrace{e^{-\frac{1}{2} (\bar{X}_n - \mu)^2}}_g$$

$\Rightarrow$ È POSSIBILE FATTORIZZARE

OBIETTIVO:

DIMOSTRARE CHE UNO STIMATORE PER ESSERE EFFICIENTE DEVE ESSERE FUNZIONE DI UNA STATISTICA SUFFICIENTE.

QUESTA IDEA È RESA RIGOROSA DAL TEOREMA DI RAO-BLACKWELL;
PRIMA DI ENUNCIARLO, DOBBIAMO RICORDARE ALCUNE NOZIONI SUL
VALORE MEDIO CONDIZIONATO.

SIANO X, Y DUE V.A. CON DISTRIBUZIONE CONGIUNTA $f(x, y)$.

$$- E[X] = \int x f_X(x) dx$$

$$- E[Y] = \int y f_Y(y) dy \quad \text{DOVE } f_X(x) = \int f(x, y) dy$$

$$- f_{X|Y}(X|Y=y) = f_{X|Y}(X|Y) = \frac{f_{XY}(x, y)}{f_Y(y)}$$

$$- E[X|y] = \int x f_{X|Y}(X|y) dx \quad (\text{NUMERO})$$

SE EVITIAMO DI FISSARE IL VALORE DELLA VARIABILE ALEATORIA Y , AUREMO

ORA UNA NUOVA VARIABILE ALEATORIA DELLA FORMA $\psi(Y) = E[X|Y]$

CHE AD OGNI VALORE DI Y ASSOCIA IL VALORE DEL VALOR MEDIO CONDIZIONATO CORRISPONDENTE A QUEL VALORE

$$E[X|Y] = E[X | \psi(Y)] = \int x f_{X|Y}(x | Y(\omega)) dx = \psi(Y)$$

VALE INOLTRE LA LEGGE DELLE ASPETTATIVE ITERATE (TH. TORRE)

$$E[E[X|Y]] = \int \psi(y) f_Y(y) dy = \iint x f_{X|Y}(x|y) dx f_Y(y) dy$$

$$= \iint x \underbrace{f_{X|Y}(x|y) f_Y(y)}_{f_{X,Y}(x,y)} dx dy$$

$$= \iint x f_{X,Y}(x,y) dx dy$$

$$= \int x \left(\underbrace{\int f_{X,Y}(x,y) dy}_{\text{DENSITA' MARGINALE } f_X(x)} \right) dx$$

$$= \int x \cdot f_X(x) dx = E[X]$$

LEMMA: SIANO X, Y V.A. CON $E[X^2] < \infty$ E $E[Y^2] < \infty$

$$\text{VAR}[X] = \text{VAR}[E[X|Y]] + E[\text{VAR}[X|Y]]$$

↓
INCERTEZZA
DELLA PREVISIONE

↓
DATO UN CERTO VALORE,
QUANTO È INCERTA LA
MIA PREVISIONE

PROOF:

$$\begin{aligned}\text{VAR}(X) &= E[(X - E[X])^2] = E[(X - E[X|Y] + E[X|Y] - E[X])^2] \\&= E_Y[E[(X - E[X|Y] + E[X|Y] - E[X])^2 | Y]] \\&= E_Y[E[(X - E[X|Y])^2 | Y] + E[(E[X|Y] - E[X])^2 | Y]] \\&= E[\text{VAR}(X|Y)] + \text{VAR}(E[X|Y])\end{aligned}$$

TEOREMA DI RAO-BLACKWELL

SIA $W = W(X_1, \dots, X_n)$ UNO STIMATORE CON LE SEGUENTI CARATTERISTICHE:

1) $E[W] = \theta_0$

2) $E[W^2] < \infty$

PRESO T LA STATISTICA SUFFICIENTE, ALLORA POSSIAMO CREARE UN NUOVO STIMATORE W' NEL SEGUENTE MODO:

$$W' = E[W|T] (= \psi(T))$$

AVENTE LE SEGUENTI CARATTERISTICHE:

1) $E[W'] = \theta_0$

2) $\text{VAR}(W') \leq \text{VAR}(W)$

PROOF:

$$1) E[W'] = E_T[E[W|T]] \overset{\text{TH TORRE}}{=} E[W] = \theta_0$$

$$2) \text{VAR}(W) = \text{VAR}(W') + \text{VAR}(E[W|T]) + E[\text{VAR}(W|T)]$$

$$\Rightarrow \text{VAR}(W) \geq \text{VAR}(W')$$

LA SUFFICIENZA GARANTISCE CHE IL VALOR MEDIO CONDIZIONATO NON DIPENDA DAL PARAMETRO, E QUINDI CHE $\psi(T)$ SIA EFFETTIVAMENTE UNO STIMATORE.

INFATTI, CONSIDERIAMO IL SEGUENTE CONTROESEMPIO:

$$X_1, X_2 \sim N(\mu, 1) \text{ E CONSIDERIAMO LO STIMATORE } \bar{X}_2 = \frac{X_1 + X_2}{2}.$$

ALLORA $\psi(X_1) := E[\bar{X}_2 | X_1] = \frac{X_1 + \mu}{2}$. NON SI TRATTA DI UNO STIMATORE PERCHÉ IL SUO VALORE NON PUÒ ESSERE DETERMINATO SENZA CONOSCERE IL VALORE DI μ .

