

STIMATORI E LORO PROPRIETÀ

Def: Definiamo campione aleatorio (random sample) un insieme di variabili aleatorie indipendenti ed identicamente distribuite $X_1, \dots, X_n$ definite su uno spazio di probabilità $\{\Omega, \mathcal{F}, P\}$

NOTA: Le ipotesi di indipendenza e di identica distribuzione non sono necessarie e saranno entrambe abbandonate più avanti; partiamo da queste condizioni super-semplificate per necessità.

Supponiamo ora che la probabilità P sia nota solo a meno di un valore di un certo parametro θ , ottenendo quindi P_θ .

In genere, si definisce

Statistica Parametrica la disciplina che studia le tecniche per risalire al valore di θ nel caso in cui esso appartenga ad uno spazio di dimensione **finito**, ovvero $\theta \in \mathbb{R}^p$ con $p \in \mathbb{N}$

Statistica Non Parametrica la disciplina che studia il caso in cui θ ha dimensione **infinita**.

Def: Uno stimatore di un certo parametro $\theta \in \mathbb{R}^p$ è una funzione (o meglio una successione di funzioni) misurabile $T_n: \mathbb{R}^n \rightarrow \mathbb{R}^p$ di un campione aleatorio.

$$T_n = \hat{\theta}_n = T_n(X_1, \dots, X_n)$$

NOTA: La definizione è molto generica: qualsiasi funzione misurabile può essere considerata uno stimatore, quindi il punto cruciale sarà determinare quali siano le proprietà che consentono di valutare la bontà della scelta fatta.

ESEMPIO

L'esempio più ovvio di stimatore (per il valore medio $\mu = E[X_i]$) è la media aritmetica empirica, cioè

$$\hat{X}_n = \hat{\mu}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

Un altro stimatore naturale è la cosiddetta varianza empirica (che stima $\sigma^2 = \text{VAR}(X_i)$), cioè

$$S_n^2 = \hat{\sigma}_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \hat{\mu}_n)^2$$

CRITERI PER VALUTARE GLI STIMATORI

Ci sono 4 criteri per valutare gli stimatori, essi sono:

1) **CORRETTEZZA** (anche chiamata **NON-DISTORSIONE**)
ASINTOTICA NON-DISTORSIONE

$$E[T_n] = \theta \quad \left(\lim_{n \rightarrow \infty} E[T_n] = \theta \right)$$

2) **CONSISTENZA** (la più importante)

a) Consistenza debole (convergenza in probabilità)

$$T_n \rightarrow_p \theta \quad \text{per } n \rightarrow \infty$$

b) Consistenza forte (convergenza quasi certa)

$$T_n \rightarrow_{q.c.} \theta \quad \text{per } n \rightarrow \infty$$

c) Consistenza r -esima (convergenza in media r -esima)

$$T_n \xrightarrow{r} \theta \quad \text{per } n \rightarrow \infty$$

d) Consistenza completa (convergenza completa)

$$T_n \xrightarrow{c.c.} \theta \quad \text{per } n \rightarrow \infty$$

3) EFFICIENZA

Presi due stimatori distinti T_n, T_n' , tra i due scegliamo quello con varianza minore, quindi diremo che T_n è più efficiente di T_n' se e solo se

$$\text{VAR}(T_n) \leq \text{VAR}(T_n')$$

4) ASINTOTICA GAUSSIANITA'

per $n \rightarrow \infty$, deve valere il CLT, ovvero che

$$\frac{T_n - \theta}{\sqrt{\text{VAR}(T_n)}} \xrightarrow{d} N(0, 1)$$

OSS

1) In generale, vale che $\textcircled{1} \not\Rightarrow \textcircled{2}$

2) $\textcircled{2} \Rightarrow \textcircled{1}$ se e solo se si tratta di consistenza in media r -esima, con $r \geq 1$. In tutti gli altri casi vale che $\textcircled{2} \not\Rightarrow \textcircled{1}$

• $\textcircled{2} \not\Rightarrow \textcircled{1}$ perché:

$$T_n = \begin{cases} 0 & 1 - \frac{1}{n^2} \\ n^2 & \frac{1}{n^2} \end{cases}, \quad \theta = 0 \Rightarrow T_n \rightarrow 0$$

ma $E[T_n] = 1 \neq \theta$

• $\textcircled{2} \Rightarrow \textcircled{1}$ per $r \geq 1$ perché:

Lemma: $T_n \rightarrow_r \theta, r \geq 1 \Rightarrow E[T_n] \rightarrow \theta$

Dim: $\lim_{n \rightarrow \infty} E[T_n - \theta] = 0$ perché $|E[T_n - \theta]| \leq E[|T_n - \theta|]$.

ESEMPIO:

Consideriamo la media aritmetica $X_n = \frac{1}{n} \sum_{i=1}^n X_i$

Se $X_i \sim i.i.d$ con $E[X_i] = \mu$ e $VAR(X_i) = \sigma^2$, allora

il stimatore $\bar{x}$ è corretto (non distorto), consistente efficiente e asintoticamente gaussiano perché vale il CLT.

METODO DEI MOMENTI (KARL-PEARSON)

Con questo metodo vogliamo generalizzare la stima che abbiamo dato usando la **media empirica** e la **varianza empirica**.

L'idea è la seguente:

- Supponiamo di avere un campione aleatorio $X_1, \dots, X_n$ estratto da una legge di probabilità P_θ , con $\theta = (\theta_1, \dots, \theta_p)$.
- Supponiamo anche che questa legge ammetta K momenti finiti, cioè

$$\mu_j = E[X_1^j] \text{ ben definito per } j=1, \dots, K$$

- Chiamiamo inoltre $\hat{\mu}_{j,n}$ i momenti empirici

$$\hat{\mu}_{j,n} = \frac{1}{n} \sum_{i=1}^n X_i^j$$

- L'idea di fondo è scegliere il valore dei parametri $\theta_1, \dots, \theta_k$ in modo che valga l'uguaglianza vettoriale

$$\hat{\mu}_{1,n} = \mu_1(\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_p)$$

$$\hat{\mu}_{2,n} = \mu_2(\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_p)$$

$$\vdots$$
$$\hat{\mu}_{k,n} = \mu_k(\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_p)$$

Def: Assumiamo che esista un diffeomorfismo

$g: \mathbb{R}^k \rightarrow \mathbb{R}^k$ tale che

$$g(\mu_1, \dots, \mu_k) = (\theta_1, \dots, \theta_k),$$

per ogni valore di $(\theta_1, \dots, \theta_k)$.

↳ funzione tra due varietà differenziabile con la proprietà di essere differenziabile, invertibile e di avere l'inversa differenziabile.

Lo stimatore del metodo dei momenti $\bar{\theta}$ allora definito da

$$\hat{\theta}_n = (\hat{\theta}_1, \dots, \hat{\theta}_k) := g(\hat{\mu}_{1,n}, \dots, \hat{\mu}_{k,n})$$

Per determinare le proprietà asintotiche del nostro stimatore dobbiamo rinforzare leggermente le nostre ipotesi.

Assumiamo quindi che le variabili aleatorie $X_1, \dots, X_n$ sono indipendenti e identicamente distribuite (i.i.d.) con momenti di ordine $2k$ finiti (per punti 3 e 4, per 1 e 2 non necessario)

Quindi, per dimostrare che il stimatore rispetti le 4 proprietà enunciate sopra è necessario:

1) Cercare delle condizioni affinché

$$\hat{\mu}_{1,n} \rightarrow_p \mu_1, \hat{\mu}_{2,n} \rightarrow_p \mu_2, \dots, \hat{\mu}_{k,n} \rightarrow_p \mu_k$$

2) Se g è una funzione continua, allora per **SLUTZKY**

$$g(\hat{\mu}_{1,n}, \dots, \hat{\mu}_{k,n}) \rightarrow_p g(\mu_1, \dots, \mu_k) = \theta$$

Con la ① e la ② dimostriamo che lo stimatore è consistente.

3) Dobbiamo poi dimostrare che

$$(\hat{\mu}_{1,n}, \dots, \hat{\mu}_{p,n}) \xrightarrow{d} N$$

dopo aver centrato e normalizzato

4) Se g è differenziabile allora applichiamo il Metodo Delta, così posso usare il CLT e far valere la proprietà di asintotica gaussianità.

Analizzando nel dettaglio ogni punto, abbiamo che:

1) Sotto le ipotesi che $\{X_i\}_{i=1, \dots, n} \sim \text{i.i.d.}$, $\theta \in \mathbb{R}^p$ e $IE[X_i^p] < \infty$

vale che $(\hat{\mu}_{1,n}, \dots, \hat{\mu}_{p,n}) \xrightarrow{p} (\mu_1, \dots, \mu_p)$.

VALE LA LGM PER UNIFORME INTEGRABILITÀ.

Non posso usare LGM con Chebychev in quanto ho bisogno che $VAR(X_i) < \infty$ e per fare ciò devo assumere che esistano finiti i momenti $2p$.

Quindi se assumo $IE[X_i^{2p}] < \infty \Rightarrow$ LGM con Chebychev.

Se assumo $IE[X_i^p] < \infty \Rightarrow$ LGM con uniforme integrabilità.

2) Sotto le ipotesi $\{X_i\}_{i=1, \dots, n} \sim \text{i.i.d.}$, $\theta \in \mathbb{R}^p$, $IE[X_i^p] < \infty$,

preso $\theta = g(\mu_1, \dots, \mu_p)$, allora

↓
vero parametro

$\hat{\theta}_n \longrightarrow \theta$
↓
stimatore

Questo vale per il Lemma di Slutsky poiché g è continua.

3) Per questo punto, abbiamo bisogno del **teorema del limite centrale multivariato**.

NOTA: CRAMER - WOLD'S DEVICE APPLICATO AL MCLT.

• MCLT: Siano $\underline{X}_1, \underline{X}_2, \dots, \underline{X}_n$ una sequenza di vettori indipendenti e identicamente distribuiti in $\mathbb{R}^k$.

- $IE[\underline{X}_i] = \mu$: **vettore delle medie**

- Matrice di covarianza: $COV(\underline{X}_i) = \Sigma$

$$- \bar{X}_n = \frac{1}{n} \sum_{i=1}^n \underline{X}_i$$

$$\text{Allora} \quad \sqrt{n}(\bar{X}_n - \mu) \xrightarrow{d} N_k(0, \Sigma)$$

Applicando Cramer - Wold device, abbiamo che

$$t^T Z \sim N(t^T \cdot 0, t^T \Sigma t) = N(0, t^T \Sigma t)$$

SOLO COME PICCOLA NOTA.

Quindi, sotto l'ipotesi che esistono i primi $2p$ momenti, allora possiamo sfruttare il **MCCT** e ottenere che

$$\sqrt{n} \begin{pmatrix} \hat{\mu}_{1,n} - \mu_1 \\ \vdots \\ \hat{\mu}_{p,n} - \mu_p \end{pmatrix} \longrightarrow_d \mathcal{N}(0, \Omega_{p \times p})$$

dove Ω è la **matrice di varianza e covarianza**.

Inoltre, $\text{Diag}_k(\Omega) = \mu_k^k - \mu_k^2$.

ESEMPIO:

Sia $X \sim f(x) = \left(\frac{1}{\sqrt{2\pi}\sigma^2}, e^{-\frac{1}{2} \left(\frac{x-\mu}{\sigma} \right)^2} \right)$ $p=1$

Se invece consideriamo $p > 1$

$$\underset{p \times 1}{X} \sim \underset{p \times 1}{f}(x_1, \dots, x_p) = \left(\frac{1}{(2\pi)^{\frac{p}{2}} (\det(\Omega))^{\frac{1}{2}}}, e^{-\frac{1}{2} \overset{1 \times p}{(x-\mu)^T} \Omega^{-1} \overset{p \times 1}{(x-\mu)}} \right)$$

4) Infine, assumendo inoltre che g sia differenziabile e che

$$(Dg) = \begin{bmatrix} \frac{\partial g_1}{\partial x_1} & \dots & \frac{\partial g_1}{\partial x_p} \\ \vdots & & \vdots \\ \frac{\partial g_p}{\partial x_1} & \dots & \frac{\partial g_p}{\partial x_p} \end{bmatrix}$$

Allora, $\sqrt{n} \begin{pmatrix} \hat{\theta}_n - \theta \\ \text{p} \times 1 \end{pmatrix} \xrightarrow{d} N \left(0, \begin{pmatrix} (Dg) \Omega (Dg)^T \\ \text{p} \times \text{p} \quad \text{p} \times \text{p} \quad \text{p} \times \text{p} \end{pmatrix} \right)$

dove (Dg) è definita come la matrice **JACOBIANA**, ovvero

$$(Dg) = Jg(\mu_1, \dots, \mu_k)$$

OSS: Per i punti ① e ② basta che esistano i primi **p** momenti finiti, se vogliamo invece arrivare anche agli altri due punti, serve necessariamente la condizione di esistenza dei primi **2p** momenti.

METODO DI MASSIMA VEROSIMIGLIANZA (MLE)

Supponiamo di avere di fronte a noi due urne, una con 90 palline bianche e 10 nere, e l'altra con 10 nere e 90 bianche.

Identifichiamo le urne con la proporzione di palline bianche che contengono p .



10 bianche 90 nere
90 bianche 10 nere

Viene estratta una singola pallina e non sappiamo da quale urna venga;

Osserviamo però che la pallina è bianca. Dovendo cercare di risalire all'urna di provenienza, sembra naturale scegliere quella che rende più probabile osservare quello che abbiamo effettivamente osservato, cioè l'urna che contiene la maggiore proporzione di palline bianche.

In altre parole, dall'osservazione "è stata estratta una pallina bianca" sembra naturale far discendere lo stimatore $\hat{p} = .9$.

Supponiamo ora che invece di una sola pallina ne siano estratte 5, e che risultino essere 3 bianche e 2 nere.

Def: Sia $X_1, \dots, X_n$ un campione aleatorio con legge f_θ
 $\theta \in \mathbb{R}^p$.

La funzione di verosimiglianza

$L: \mathbb{R}^p \rightarrow \mathbb{R}$ è definita da

$$L(\theta; X_1, \dots, X_n) := \prod_{i=1}^n f(X_i; \theta) = f(X_1, \dots, X_n; \theta)$$

funzione di
probabilità

densità

Dal punto di vista analitico la verosimiglianza è il prodotto delle densità congiunte. MA, bisogna interpretarla in modo diverso. La DENSITÀ è funzione dei dati $X_1, \dots, X_n$ fissato il parametro θ mentre la VEROSIMIGLIANZA è funzione del parametro fissati i dati.

Densità: Se il parametro è θ , qual è la probabilità di osservare il dato x ?

Verosimiglianza: Dati questi valori X_i , quanto è credibile che il parametro sia θ ?

NOTA: Ovviamente, nel caso continuo,

$$\int_{\mathbb{R}^n} f(x_1, \dots, x_n, \theta) dx_1, \dots, dx_n = 1$$

MA

$$\int_{\mathbb{R}^p} L(\theta; X_1, \dots, X_n) d\theta \stackrel{??}{=} 1$$


IN GENERALE NO, ANZI
QUESTO INTEGRALE PUO' DIVERGERE

LA FUNZIONE DI VEROSIMIGLIANZA NON IDENTIFICA
UNA DENSITA'

Def: STIMATORE DI MASSIMA VEROSIMIGLIANZA

$$\hat{\theta}_{ML} = \operatorname{argmax}_{\theta \in \Theta \subseteq \mathbb{R}^p} L_{\theta}(X_1, \dots, X_n)$$

→ $\max L(\theta)$: valore più alto raggiunto dalla funzione.

→ $\operatorname{argmax} L(\theta)$: il valore di θ per cui si ottiene il valore più alto della funzione.

Non ci importa quanto sia alta la verosimiglianza in assoluto ma ci interessa sapere **QUALE** θ la massimizza.

PRINCIPIO DI VEROSIMIGLIANZA

→ TUTTA L'INFORMAZIONE CHE I DATI CI DANNO SUL PARAMETRO θ È CONTENUTA ESCLUSIVAMENTE NELLA FUNZIONE $L(\theta)$

→ SE DUE ESPERIMENTI DIVERSI PRODUCONO FUNZIONI DI VEROSIMIGLIANZA PROPORZIONALI, ALLORA DEVONO PORTARE ALLE STESSA IDENTICHE CONCLUSIONI SU θ .

ESEMPIO

Alice e Bob devono testare se una moneta è truccata (θ). Entrambi ottengono gli stessi dati:

12 lanci $\begin{cases} \rightarrow 3 \text{ TESTE} \\ \rightarrow 9 \text{ CROCI} \end{cases}$

Alice: Decide **prima** di lasciare 12 volte:

$$P_v[3 T \text{ su } 12 \text{ lanci}] = L_A(\theta) = \binom{12}{3} \theta^3 (1-\theta)^9$$

Bob: Decide **prima** di continuare a lanciare finché non otteneva 3 teste.

Supponiamo sia uscita la 3° testa la 12° lancio:

$$\Pr[3^{\circ} \text{ testa la } 12^{\circ} \text{ Lancio}] = L_B(\theta) = \binom{11}{2} \theta^3 (1-\theta)^9$$

$$L_A(\theta) = \binom{12}{3} \theta^3 (1-\theta)^9$$

$$L_B(\theta) = \binom{11}{2} \theta^3 (1-\theta)^9$$

$L_A(\theta)$ e $L_B(\theta)$ differiscono solo per il coefficiente binomiale. La parte dipendente da θ è identica, quindi MLE è lo stesso per entrambi: $\hat{\theta}_{MLE} = \frac{3}{12}$.

Per il **PRINCIPIO DI VEROSIMIGLIANZA**, poiché A e B hanno le **STESSE EVIDENZE**, allora devono trarre le **STESSE CONCLUSIONI**.

ESEMPIO 1

$X_1, \dots, X_n \sim \text{BER}(p)$ UN CAMPIONE ALEATORIO. TROVARE $\hat{p}_{MLE}$.

1) SCRIVERE LA FUNZIONE DI VEROSIMIGLIANZA

LA PROBABILITÀ DI K SUCCESSI PER $K=0, 1, \dots, n$ È DATA DA:

$$\underbrace{p^k (1-p)^{n-k}}_{\text{CONOSCIAMO } p} \Rightarrow L(\theta; X_1, \dots, X_n) = \underbrace{\theta^{\sum_{i=1}^n X_i} (1-\theta)^{n - \sum_{i=1}^n X_i}}_{\text{CONOSCIAMO GLI ESITI E LI USIAMO PER STIMARE } \theta(p)}$$

2) $\log L$

$$\log L(\theta; X_1, \dots, X_n) = \left(\sum_{i=1}^n X_i \right) \log \theta + \left(n - \sum_{i=1}^n X_i \right) \log(1-\theta)$$

3) MASSIMIZZIAMO $\log L \Rightarrow$ DERIVATA PRIMA RISPETTO A θ

$$\frac{\partial \log L(\theta; X_1, \dots, X_n)}{\partial \theta} = \left(\sum_{i=1}^n X_i \right) \frac{\partial \log \theta}{\partial \theta} + \left(n - \sum_{i=1}^n X_i \right) \frac{\partial \log(1-\theta)}{\partial \theta}$$

$$= \frac{\sum_{i=1}^n X_i}{\theta} - \frac{n - \sum_{i=1}^n X_i}{1 - \theta}$$

$$\frac{\partial \log(1-\theta)}{\partial \theta} = \frac{1}{1-\theta} \cdot \partial(1-\theta) = -\frac{1}{1-\theta}$$

PER TROVARE $\arg \max_{\theta} \log(\theta)$ PONIAMO $\partial \log l = 0$

$$\frac{\sum_{i=1}^n X_i}{\theta} - \frac{n - \sum_{i=1}^n X_i}{1 - \theta} = 0 \Leftrightarrow (1-\theta) \sum_{i=1}^n X_i - \theta \left(n - \sum_{i=1}^n X_i \right) = 0$$

$$\Leftrightarrow \sum_{i=1}^n X_i - \theta \cancel{\sum_{i=1}^n X_i} - \theta n + \theta \cancel{\sum_{i=1}^n X_i} = 0$$

$$\Leftrightarrow \theta = \frac{1}{n} \sum_{i=1}^n X_i$$

QUINDI

$$\hat{\theta}_{MLE} = \frac{1}{n} \sum_{i=1}^n X_i$$

OSS: AVREMO POTUTO SCRIVERE LA FUNZIONE DI ML COME

$$L(\theta; X_1, \dots, X_n) = \binom{n}{\sum_{i=1}^n X_i} \theta^{\sum_{i=1}^n X_i} (1-\theta)^{n - \sum_{i=1}^n X_i}$$

SCRITTA IN QUESTO MODO PRENDIAMO UNA QUALSIASI SEQUENZA DI SUCCESSI, MENTRE NEL PRIMO CASO PRENDIAMO UN'ESATTA SEQUENZA DI SUCCESSI, SONO EQUIVALENTI, IN QUANTO PASSANDO ALLA $\log L$, $\binom{n}{\sum_{i=1}^n X_i}$ DIVENTAVA $\log \binom{n}{\sum_{i=1}^n X_i}$ IL QUALE È UNA COSTANTE E SPARIVA NELLA DERIVATA.

4) PER COMPLETEZZA SI CALCOLA ANCHE LA DERIVATA SECONDA E SI VERIFICA CHE $\hat{\theta}_{ML}$ SIA VERAMENTE UN MASSIMO, OVVERO CHE LA DERIVATA SECONDA SIA NEGATIVA, RIVOLTA VERSO IL BASSO (CONCAVITÀ NEGATIVA)

ESEMPIO 2

$X_1, \dots, X_n$ CAMPIONE ALEATORIO CON DENSITA'

$$f(x) = \lambda e^{-\lambda x}, \quad x \geq 0 \quad \text{OPPURE} \quad f(x) = \frac{1}{\theta} e^{-\frac{x}{\theta}} \quad x \geq 0$$

$\lambda = \frac{1}{\theta}$

$$L(\lambda; X_1, \dots, X_n) = \lambda^n e^{-\lambda \sum_{i=1}^n X_i}$$

$\Downarrow$

$$\log L(\lambda; X_1, \dots, X_n) = n \log(\lambda) - \lambda \sum_{i=1}^n X_i$$

$$\frac{\partial \log L(\lambda; X_1, \dots, X_n)}{\partial \lambda} = \frac{n}{\lambda} - \sum_{i=1}^n X_i$$

$$\Rightarrow \hat{\lambda}_{MLE} = \frac{n}{\sum_{i=1}^n X_i}$$

$$L(\theta; X_1, \dots, X_n) = \left(\frac{1}{\theta}\right)^n e^{-\sum_{i=1}^n X_i \frac{1}{\theta}}$$

$$\log L(\theta; X_1, \dots, X_n) = -n \log(\theta) - \frac{1}{\theta} \sum_{i=1}^n X_i$$

$$\frac{\partial \log L(\theta; X_1, \dots, X_n)}{\partial \theta} = -\frac{n}{\theta} + \frac{1}{\theta^2} \sum_{i=1}^n X_i$$

$$-n\theta + \sum_{i=1}^n X_i = 0 \Leftrightarrow \hat{\theta}_{MLE} = \frac{\sum_{i=1}^n X_i}{n}$$

OSSERVAZIONI

1) PROPRIETÀ DI INVARIANZA

SE SI STIMA UN PARAMETRO θ CON $\hat{\theta}_{ML}$ E POI SI STIMA $g(\theta)$, SI OTTIENE $g(\hat{\theta}_{ML})$, INFATTI:

$$\lambda = \frac{1}{\theta} \Rightarrow \hat{\lambda}_{ML} = \frac{1}{\hat{\theta}_{ML}} \quad \bigg| \quad \hat{\lambda}_{ML} = \frac{n}{\sum_{i=1}^n X_i} \quad \bigg| \quad \hat{\theta}_{ML} = \frac{1}{n} \sum_{i=1}^n X_i$$

2) DISTORSIONE VS INVARIANZA

LO STIMATORE $\hat{\theta}_{ML} = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ È **NON DISTORTO**, INFATTI

$$E[\hat{\theta}_{ML}] = E[\bar{X}] = \theta$$

LO STIMATORE $\hat{\lambda}_{ML} = \frac{1}{\bar{X}}$ È **DISTORTO**, INFATTI

$$E[\hat{\lambda}_{ML}] = E\left[\frac{1}{\bar{X}}\right] \neq \frac{1}{E[\bar{X}]} = \frac{1}{\theta} = \lambda$$

PER JENSEN:
 $E[g(X)] > g(E[X])$

IN CONCLUSIONE, NON SI PUÓ AVERE INVARIANZA E NON DISTORSIONE INSIEME.

ESEMPIO 3.

STIMARE MLE PER LA DISTRIBUZIONE NORMALE (GAUSSIANA)

$X_1, \dots, X_n$ I.I.D., $X_i \sim N(\mu, \sigma^2)$, STIMARE $\Theta = (\mu, \sigma^2)$

LA PDF (DENSITA') È:

$$f(x_i; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-1/2 \frac{(x_i - \mu)^2}{\sigma^2}}$$

$$L(\mu, \sigma^2; X_1, \dots, X_n) = \prod_{i=1}^n f(x_i; \mu, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-1/2 \frac{(x_i - \mu)^2}{\sigma^2}}$$

$$= \frac{1}{(2\pi\sigma^2)^{n/2}} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2}$$

CALCOLIAMO ORA LA $\log L$.

$$\log L = \log \left(\frac{1}{(2\pi\sigma^2)^{n/2}} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (X_i - \mu)^2} \right)$$

APPLICANO

$$\log(ab) = \log(a) + \log(b)$$

$$\log(a^b) = b \log(a)$$

$$= -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (X_i - \mu)^2$$

DOBBIAMO ORA DERIVARE E PORRE UGUALE A 0.

IN QUESTO CASO I PARAMETRI DA STIMARE SONO 2, $\Theta = (\mu, \sigma^2)$

QUINDI DOBBIAMO CALCOLARE LE DERIVATE PARZIALI.

$$\frac{\partial \log L}{\partial \mu} = 0 - 0 - \frac{1}{2\sigma^2} \frac{\partial \sum_{i=1}^n (X_i - \mu)^2}{\partial \mu} = \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \mu)$$

$$\frac{\partial \log L}{\partial \sigma^2} = 0 - \frac{n}{2} \frac{\partial \log(\sigma^2)}{\partial \sigma^2} - \sum_{i=1}^n (X_i - \mu)^2 \frac{\partial}{\partial \sigma^2} \frac{1}{2\sigma^2}$$

$$= -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (X_i - \mu)^2$$

$$\frac{\partial \log L}{\partial \mu} = \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \mu) = 0 \Leftrightarrow n\mu = \sum_{i=1}^n X_i$$

$$\Leftrightarrow \hat{\mu}_{ML} = \frac{\sum_{i=1}^n X_i}{n} = \bar{X}$$

$$\frac{\partial \log L}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (X_i - \mu)^2 = 0$$

$$\Rightarrow \sigma_{ML}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

$$\Rightarrow \hat{\Theta}_{ML} = \left(\hat{\mu}_{ML}, \sigma_{ML}^2 \right) = \left(\bar{X}, \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \right)$$

CONSISTENZA METODO DI MASSIMA VEROSIMIGLIANZA

DEF: DISTANZA DI KULLBACK-LEIBLER

SIANO f E g FUNZIONI DI DENSITA' O FUNZIONI DI PROBABILITA'.
LA DISTANZA DI KULLBACK-LEIBLER TRA f E g E' DEFINITA DA:

$$D(f, g) = \int \log \left[\frac{f(x, \theta)}{g(x, \theta)} \right] f(x; \theta) dx$$

SE f E' ASSOLUTAMENTE CONTINUA RISPETTO A g , ALTREMENTI LA DISTANZA VIENE POSTA A $+\infty$.

$$D(f, g) = \sum_{x_i} \log \left[\frac{p(x_i, \theta)}{q(x_i, \theta)} \right] p(x_i; \theta)$$

$f(x) \ll g(x)$

$g(x) = 0 \Rightarrow f(x) = 0$

PROPRIETÀ:

1) NON SIMMETRICA: $D(f, g) \neq D(g, f)$. NON IDENTIFICA UNA METRICA

2) $\text{Se } f = g \Rightarrow D(f, g) = 0$
3) $\text{Se } f \neq g \Rightarrow D(f, g) > 0$ } $\Rightarrow D(f, g) \geq 0$ SEMPRE

PROOF 3.

$$D(f, g) = \int \ln \left[\frac{f(x)}{g(x)} \right] f(x) dx = E_f \left[\ln \left(\frac{f(x)}{g(x)} \right) \right]$$
$$= E_f \left[-\ln \left(\frac{g(x)}{f(x)} \right) \right]$$

↓
RIBALTANDOLA, OTTENGO
UNA FUNZIONE CONVESSO
E APPLICO JENSEN

↓
PER DEFINIZIONE DI VALOR ATTESO RISPETTO
ALLA DISTRIBUZIONE $f(x)$, IN GENERALE

$$E_p \left[\log \left(\frac{f(x)}{g(x)} \right) \right] = \int p(x) \cdot \log \left[\frac{f(x)}{g(x)} \right] dx.$$



$$D(f, g) \geq -\ln \left(\mathbb{E}_f \left[\frac{g(x)}{f(x)} \right] \right)$$

$$= -\ln \int \frac{g(x)}{\cancel{f(x)}} \cancel{f(x)} dx$$

DEF DI VALOR
ATTESO

$$= -\ln \int g(x) dx = -\ln(1) = 0$$

$g(x)$ È UNA PDF, PER DEF. L'INTEGRALE FA 1.



RELAZIONE TRA K-L E ML.

POSSIAMO SCRIVERE LA $\log L$ IN TERMINI DI DISTANZA DI K-L.

$$L(\theta; X_1, \dots, X_n) = \prod_{i=1}^n f(X_i; \theta)$$

$$\downarrow \log L$$

$$\log L(\theta; X_1, \dots, X_n) = \sum_{i=1}^n \log [f(X_i; \theta)]$$

DEFINIAMO ORA

$$M_n(\theta) = \frac{1}{n} \sum_{i=1}^n \log [f(X_i; \theta)] - \frac{1}{n} \sum_{i=1}^n \log [f(X_i; \theta_0)]$$

$$= \frac{1}{n} \sum_{i=1}^n \log \left[\frac{f(X_i; \theta)}{f(X_i; \theta_0)} \right]$$

θ_0 È IL VERO VALORE DEL
PARAMETRO

SOTTO ALCUNE CONDIZIONI DI REGOLARITÀ AFFINCHÉ VALGA LA LEGGE DEI GRANDI NUMERI, ABBIAMO CHE, AD UN VALORE FISSATO DI θ

$$M_n(\theta) = \frac{1}{n} \sum_{i=0}^n \log \left[\frac{f(X_i; \theta)}{f(X_i; \theta_0)} \right] \xrightarrow{P} E \left[\log \left[\frac{f(X_i; \theta)}{f(X_i; \theta_0)} \right] \right]$$

↑
MEDIA
IMPIRICA

↑
VERO
VALOR ATTESO

$$= \int \log \left[\frac{f(x; \theta)}{f(x; \theta_0)} \right] f(x; \theta_0) dx = -D(f_{\theta_0}, f_{\theta})$$

$$= D(f_{\theta}, f_{\theta_0})$$

CI RIMANE SOLO DA DIMOSTRARE LA CONSISTENZA DELLO STIMATORE.

LO SKETCH DELLA DIMOSTRAZIONE È IL SEGUENTE:

- 1) DEFINIAMO $M_n(\theta)$
- 2) DIMOSTRIAMO CHE $M_n(\theta) \xrightarrow{P} D(\theta_0, \theta)$
- 3) DIMOSTRIAMO CHE
 $P(|\hat{\theta}_{ML} - \theta_0| > \delta) \rightarrow 0 \Rightarrow \hat{\theta}_{ML} = \theta_0$

TEOREMA - CONSISTENZA MLE

Sia $M_n(\theta) = \frac{1}{n} \sum_{i=1}^n \log \left[\frac{f(X_i; \theta)}{f(X_i; \theta_0)} \right]$ E sia $M(\theta) = -D(f_{\theta_0}, f_{\theta})$

SUPPONIAMO VERE LE SEGUENTI IPOTESI:

1) LEGGE DEI GRANDI NUMERI UNIFORME

$$\sup |M_n(\theta) - M(\theta)| = o_p(1) \text{ PER } n \longrightarrow \infty$$

2) CONVESSITÀ

$\forall \varepsilon > 0 \exists \eta_\varepsilon > 0$ TALE CHE

$$|\theta - \theta_0| > \varepsilon \Rightarrow |M(\theta) - M(\theta_0)| > \eta_\varepsilon$$

ALLORA $\hat{\theta}_{MLE} \xrightarrow{p} \theta_0$.

PROOF:

L'IDEA DELLA DIMOSTRAZIONE È CHE $\forall \epsilon > 0$ FISSATO
SI HA CHE

NOTA: $A \Rightarrow B$ ALLORA
 $P(B) \leq P(A)$

$$P(|M(\theta_0) - M(\hat{\theta}_{ML})| > \eta_\epsilon) \longrightarrow 0$$

GRAZIE ALLA PROP. DI CONVESSITÀ +

$$P(|\theta_0 - \hat{\theta}_{ML}| > \epsilon) \leq \underbrace{P(|M(\theta_0) - M(\hat{\theta}_{ML})| > \eta_\epsilon)}$$

DIMOSTRIAMO QUESTO. SE TENDE A 0
ALLORA AUTOMATICAMENTE ABBIAMO DIMOSTRATO
IL TEOREMA.

PER DEFINIZIONE DI STIMATORE $M_n(\hat{\theta}_{ML}) - M_n(\theta_0) > 0$

$$\begin{aligned} \Rightarrow M(\hat{\theta}_{ML}) - M(\theta_0) &= M_n(\theta_0) - M(\theta_0) + M(\hat{\theta}_{ML}) - M_n(\theta_0) \\ &\leq M_n(\hat{\theta}_{ML}) - M(\theta_0) + M(\hat{\theta}_{ML}) - M_n(\theta_0) \end{aligned}$$

$\hat{\theta}_{ML}$ È IL
MAX

$$\leq \underbrace{|M(\theta_0) - M_n(\theta_0)|}_{\text{red}} + \underbrace{|M_n(\hat{\theta}_{ML}) - M(\hat{\theta}_{ML})|}_{\text{blue}}$$

Qui θ_0 È UN NUMERO
FISSO. VALE QUINDI LA
LGN STANDARD, QUINDI
QUESTO TENDE A 0

Qui $\hat{\theta}_{ML}$ È UNA V.A. LA LGN
STANDARD NON BASTA.
USIAMO QUINDI L'IPOTESI ①
DI CONVERGENZA UNIFORME.
POICHÉ CONVERGE UNIFORMEMENTE
PER TUTTI I θ , ALLORA VALE
ANCHE PER $\hat{\theta}_{ML}$. QUINDI
TENDE A 0.

IN CONCLUSIONE $P(|M(\hat{\theta}_{ML}) - M(\theta_0)| > \varepsilon) \longrightarrow 0$ E QUINDI
ANCHE $P(|\hat{\theta}_{ML} - \theta_0| > \varepsilon) \longrightarrow 0$

ASSINTOTICA GAUSSIANA MLE

DEF - FUNZIONE PUNTEGGIO: LA FUNZIONE PUNTEGGIO (SCORE FUNCTION)
È DEFINITA DA:

$$S_n(\theta; X_1, \dots, X_n) = \begin{cases} \frac{d}{d\theta} \log L(\theta; X_1, \dots, X_n) & \dim(\theta) = 1 \\ \nabla_{\theta} \log L(\theta; X_1, \dots, X_n) & \dim(\theta) = d \times 1 \\ & d > 1 \end{cases}$$

ASSUMENDO OVVIAMENTE CHE LA DERIVATA ESISTA. IN GENERE, SI TRATTA DI UNA FUNZIONE DA $\mathbb{R}^p$ A $\mathbb{R}^p$.

OSS: S_n È UNA VARIABILE ALEATORIA, DI CONSEGUENZA CI INTERESSA CONOSCERE $E[S_n]$ E $VAR[S_n]$.

DEF - CONDIZIONI DI REGOLARITÀ: VALGONO LE SEGUENTI IPOTESI:

- 1) L È CONDIZIONI DI CONSISTENZA
- 2) $X_1, \dots, X_n$ SONO I. I. D.
- 3) LA LOG-VEROSIMIGLIANZA AMMETTE DUE DERIVATE CONTINUE: $\frac{\partial^2 \log L}{\partial \theta^2} \in C^2$
- 4) LA DERIVATA SECONDA HA MOMENTO FINITO: $E\left[\frac{\partial^2 \log L}{\partial \theta^2}\right] < \infty$
- 5) θ_0 VERO VALORE DEL PARAMETRO APPARTIENE ALL'INTERNO DELL'INSIEME DEI VALORI AMMISSIBILI: $\theta_0 \in \text{INT}(\Theta)$
- 6) È POSSIBILE SCAMBIARE DUE VOLTE LA DERIVATA CON L'INTEGRALE NEL VALOR MEDIO DELLA LOG-VEROSIMIGLIANZA

$$\frac{\partial}{\partial \theta} \int f(x; \theta) dx = \int \frac{\partial}{\partial \theta} f(x; \theta) dx$$

LEMMA: SOTTO LE CONDIZIONI DI REGOLARITA'

$$E[S_n(\theta)]|_{\theta=\theta_0} = 0$$

PROOF: DIMOSTRAZIONE NEL CASO $d=1$.

$$0 = \frac{d}{d\theta} 1 = \frac{d}{d\theta} \int_{\mathbb{R}} f(x; \theta) dx = \int_{\mathbb{R}} \frac{d}{d\theta} f(x; \theta) \Big|_{\theta=\theta_0} dx$$

6

$$= \int_{\mathbb{R}} \frac{\frac{d}{d\theta} f(x; \theta)}{f(x; \theta)} f(x; \theta) dx = \int_{\mathbb{R}} \frac{d}{d\theta} \log L(\theta; x) \Big|_{\theta=\theta_0} f(x; \theta) dx$$

$$\frac{d \log(f(x; \theta))}{d\theta}$$

$$= E[S_n(\theta)]|_{\theta=\theta_0}$$

ESEMPIO

$$X \sim N(\mu, 1)$$

$$L = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}(X-\mu)^2} \Rightarrow \log L = -\frac{1}{2} \ln(2\pi) - \frac{1}{2}(X-\mu)^2$$

$$\Rightarrow \frac{\partial \log L}{\partial \mu} = X - \mu = S_n$$

$$E[S_n(\mu)] = E[X - \mu] = E[X] - \mu = \mu_0 - \mu \Big|_{\mu=\mu_0} = 0.$$

LEMMA: SOTTO LE CONDIZIONI DI REGOLARITÀ

$$\text{VAR}[S(\theta)] \Big|_{\theta=\theta_0} = E \left[\left(\frac{\partial \log L}{\partial \theta} \right)^2 \right] \Big|_{\theta=\theta_0} = -E \left[\frac{\partial^2 \log L}{\partial^2 \theta} \right] \Big|_{\theta=\theta_0} \quad d=1$$

$$\text{VAR}[S(\theta)] = E \left[\underbrace{(\nabla \log L)}_{d \times 1} \underbrace{(\nabla \log L)^T}_{1 \times d} \right] = -E \left[\underbrace{\mathcal{H} \log L}_{d \times d} \right] \quad d > 1$$

DO HE $\mathcal{H}$ È L'HESSIANO (MATRICE DI DERIVATE PARZIALI SECONDE)

PROOF:

$$\frac{\partial}{\partial \theta} 0 = 0 = \frac{\partial}{\partial \theta} \int \frac{\partial \log L}{\partial \theta} f(x; \theta) dx = \int \frac{\partial^2 \log L}{\partial \theta^2} f(x; \theta) dx$$

$$+ \underbrace{\int \frac{\partial \log L}{\partial \theta} \frac{\partial}{\partial \theta} f(x; \theta) dx}_{\text{6}} = \int \frac{\partial^2 \log L}{\partial \theta^2} f(x; \theta) dx + \int \frac{\partial \log L}{\partial \theta} \frac{\partial}{\partial \theta} \frac{f(x; \theta)}{f(x; \theta)} f(x; \theta) dx$$

BISOGNA FAR COMPARIRE
LA DERIVATA DEL LOGARITMO

$$= \int \frac{\partial^2 \log L}{\partial \theta^2} f(x; \theta) dx + \int \left(\frac{\partial \log L}{\partial \theta} \right)^2 f(x; \theta) dx.$$

$$E \left[\frac{\partial^2 \log L}{\partial \theta^2} \right] + E \left[\left(\frac{\partial \log L}{\partial \theta} \right)^2 \right] = 0.$$

TEOREMA: SOTTO LE CONDIZIONI DI REGOLARITÀ

$$\bullet \frac{\hat{\theta}_{ML} - \theta_0}{\sqrt{\text{VAR}(\hat{\theta}_{ML})}} \xrightarrow{d} N(0, 1) \quad d = 1$$

$$\bullet \sqrt{n} (\hat{\theta}_{ML} - \theta_0) \xrightarrow{d} N\left(0, \underset{d \times 1}{\text{IE}} \left[\underset{d \times d}{\frac{d^2 \log L}{d\theta^2}} \right]^{-1}\right) \quad d > 1$$

$$\hookrightarrow \sqrt{n} (\hat{\theta}_{ML} - \theta_0) \xrightarrow{d} N\left(0, \underset{d \times 1}{I_n(\theta_0)^{-1}}\right)$$

DOVE $I(\theta_0) = -\text{IE} \left[\frac{d^2 \log L}{d\theta^2} \right]$ È L'INFORMAZIONE DI FISHER

DOVE $I_n(\theta_0) = -\text{IE} [\mathcal{H} \log L |_{\theta = \theta_0}]$ DETTA MATRICE DI
INFORMAZIONE

PROOF: CASO $d = 1$.

PER IL TEOREMA DEL VALOR MEDIO DI LAGRANGE, ESISTE $\bar{\theta}$ INTERMEDIO TRA $\hat{\theta}_{ML}$ E θ_0 PER CUI VALE L'UGUAGLIANZA

$$0 = \log' L(\hat{\theta}_{ML}) = \log L'(\theta_0) + \log L''(\bar{\theta})(\hat{\theta}_{ML} - \theta_0)$$

VALE 0 PER LA (5), NELLO SPECIFICO LA (5) VALE PER θ_0 , MA POICHÉ $\bar{\theta}$ È CONSISTENTE, $\hat{\theta}_{ML}$ È INTERNO, QUINDI PER $n \rightarrow \infty$ TENDE A 0.

$$\log L'(\theta_0) + \log L''(\bar{\theta})(\hat{\theta}_{ML} - \theta_0) = 0 \Rightarrow$$
$$(\hat{\theta}_{ML} - \theta_0) = -\frac{\log L'(\theta_0)}{\log L''(\bar{\theta})} \Rightarrow \sqrt{n}(\hat{\theta}_{ML} - \theta_0) = -\frac{\overbrace{\log L'(\theta_0)}^{S_n(\theta)} / \sqrt{n}}{\log L''(\bar{\theta}) / n}$$

PER IL NUMERATORE ABBIAMO UNA SOMMA DI VARIABILI ALEATORIE IID CON VALOR MEDIO NULLO E VARIANZA FINITA; POSSIAMO QUINDI APPLICARE IL TLC

PROP. DELLA SCORE FUNCTION

$$\frac{\log L'(\theta_0)}{\sqrt{n}} = \frac{1}{\sqrt{n}} \sum_{i=1}^n \left. \frac{\partial \log f(X_i; \theta)}{\partial \theta} \right|_{\theta=\theta_0} \longrightarrow_d N(0, \underline{I_1(\theta_0)})$$

$\text{VAR}(S_n) = I_n(\theta)$

PER IL DENOMINATORE ABBIAMO UNA SOMMA DI V.A. I.I.D. CON VALOR MEDIO FINITO, QUINDI VALE U.I. TLC E IL TEOREMA DI SLUTZKY

$$\frac{\log L''(\bar{\theta})}{n} = \frac{1}{n} \sum_{i=1}^n \left. \frac{\partial^2 \log f(X_i; \theta)}{\partial^2 \theta} \right|_{\theta=\bar{\theta}} \longrightarrow_p -I_1(\theta_0)$$

$$\Rightarrow \frac{-\log L'(\theta_0)/\sqrt{n}}{\log L''(\bar{\theta})/n} = \frac{N(0, I_1(\theta_0))}{I_1(\theta_0)} = N(0, I_1^{-1}(\theta_0))$$

INFORMAZIONE DI FISHER

POICHÉ LA VARIANZA È UN OPERATORE QUADRATICO :

$$\text{VAR} = \frac{\text{VAR NUM}}{(\text{DEN})^2} = \frac{I_1(\theta_0)}{I_1(\theta_0)^2} = I_1^{-1}(\theta_0)$$

ESEMPIO: ESEMPIO QUANDO NON VALE IL TEOREMA

SIANO $X_1, \dots, X_n \sim U[0, \theta]$ POICHÉ DIPENDE DA θ , NON VALE LA ⑥

$$L(\theta; X_1, \dots, X_n) = \prod_{i=1}^n \frac{1}{\theta} 1_{[0, \theta]}(X_i) = \frac{1}{\theta^n} 1_{[0, \theta]}(X_n)$$

↓
IL VALORE MAX DELLE X_i

A QUESTO PUNTO, $\hat{\theta}_{HL} = X_{(n)}$, PERCHÉ SE $\theta < X_{(n)}$ ALLORA $L \rightarrow 0$

$$P(n(\theta_0 - X_{(n)}) > \varepsilon) = P\left(\theta_0 - X_{(n)} > \frac{\varepsilon}{n}\right) = \left(1 - \frac{\varepsilon}{\theta_0}\right)^n \longrightarrow e^{-\varepsilon/\theta_0}$$

RISULTA QUINDI CHE LA DISTRIBUZIONE LIMITE È ESPONENZIALE E NON GAUSSIANA, DI CONSEGUENZA NON VALE IL TEOREMA.

EFFICIENZA DELLA VEROSIMIGLIANZA

DEF: STIMATORI "BUE" - BEST UNBIASED ESTIMATOR

UNO STIMATORE SI DICE BUE SE VALE LA NON DISTORSIONE ($E[T_n] = \theta_0$)

E PER OGNI ALTRO STIMATORE T_n' : $E[T_n'] = \theta_0$, ALLORA $VAR(T_n) \leq VAR(T_n')$.

LEMMA: SE ESISTE LO STIMATORE BUE, ALLORA LUI È UNICO.

PROOF: CASO $d=1$

PER ASSURDO. ASSUMIAMO CHE ESISTA UN SECONDO STIMATORE T_n' BUE. DA T_n E T_n' DERIVIAMO UNO STIMATORE IBRIDO T_n'' NON DISTORTO COME COMBINAZIONE COMPLESSA.

$$T_n'' = \alpha T_n + (1-\alpha) T_n'' \quad \alpha \in [0, 1]$$

LA CONTRADDIZIONE SARA' NEL OTTENERE CHE $VAR(T_n'') < VAR(T_n) = VAR(T_n')$

$$VAR(T_n'') = VAR(\alpha T_n + (1-\alpha) T_n') = \alpha^2 VAR(T_n) + (1-\alpha)^2 VAR(T_n') + 2\alpha(1-\alpha) COV(T_n, T_n')$$

SIA $\sigma^2 = VAR(T_n) = VAR(T_n')$, ALLORA

$$VAR(T_n'') = \sigma^2 (\alpha^2 + (1-\alpha)^2) + 2\alpha(1-\alpha) COV(T_n, T_n')$$

USANDO LA DISUGUAGLIANZA DI CAUCHY-SCHWARTZ, POSSIAMO SCRIVERE LA COVARIANZA COME

$$\text{COV}(T_n, T_n') = \rho \sqrt{\text{VAR}(T_n) \text{VAR}(T_n')} = \rho \sigma^2$$

ρ : CORRELAZIONE

$$\downarrow$$
$$\rho = \frac{\text{COV}(T_n, T_n')}{\sqrt{\text{VAR}(T_n) \text{VAR}(T_n')}}}$$

$$\Rightarrow \text{VAR}(T_n'') = \sigma^2 [\alpha^2 + (1-\alpha)^2 + 2\alpha(1-\alpha)\rho]$$

Se $\rho < 1$ (OVVERO CHE T_n E T_n' NON SONO IDENTICI) OTTERREMO CHE $\text{VAR}(T_n'') < \sigma^2$, MA QUESTO È IMPOSSIBILE IN QUANTO PER IPOTESI $\sigma^2 = \text{VAR}(T_n) = \text{VAR}(T_n')$ È LA VARIANZA MINIMA POSSIBILE PER UNO STIMATORE NON DISTORTO.

L'UNICA SOLUZIONE È CHE $\rho = 1$, OSSIA CHE $T_n = T_n'$.

QUINDI LO STIMATORE BUE È UNICO!

TEOREMA: LIMITE INFERIORE DI CRAMER-RAO - CASO $d=1$

SOTTO LE CONDIZIONI DI REGOLARITÀ, LA VARIANZA MINIMA È DATA DALL'INVERSO DELLA MATRICE DI INFORMAZIONE.

1) CASO NON DISTORTO ($E[T_n] = \theta_0$)

$$\text{VAR}(T_n) \geq \frac{1}{I_n(\theta_0)} = \frac{1}{n I_1(\theta_0)}$$

2) CASO GENERALE

$$\text{VAR}(T_n) \geq \left(\frac{d}{d\theta} E[T_n] \Big|_{\theta=\theta_0} \right)^2 \cdot \frac{1}{I_n(\theta_0)}$$

PROOF: PER LA DISUGUAGLIANZA DI CAUCHY-SCHWARTZ,

$$\text{COV}^2(X, Y) \leq \text{VAR}(X) \text{VAR}(Y) \Rightarrow \text{VAR}(Y) \geq \frac{\text{COV}^2(X, Y)}{\text{VAR}(X)}$$

PRENDIAMO ORA

$$-Y = T_n \text{ E } \text{VAR}(Y) = \text{VAR}(T_n)$$

$$-X = S_n(\theta; X_1, \dots, X_n) = \frac{\partial}{\partial \theta} \log L(\theta; X_1, \dots, X_n) \quad \text{SCORE FUNCTION}$$

RICHIAMO
PROP.

$$1) E[S_n(\theta; X_1, \dots, X_n) | \theta = \theta_0] = 0$$

$$2) E[S_n^2(\theta; X_1, \dots, X_n) | \theta = \theta_0] = I_n(\theta_0) = -E\left[\frac{\partial^2 \log L}{\partial \theta^2}\right]$$

$$\text{DA QUESTO, ABBIAMO CHE } \text{VAR}(T_n) \geq \frac{\text{COV}(S_n, T_n)}{I_n(\theta_0)} \quad ??$$

$$\text{RESTA DA DIMOSTRARE CHE } \text{COV}(S_n, T_n) = \frac{\partial}{\partial \theta} E[T_n]$$

$$\frac{d}{d\theta} E[T_n] = \frac{d}{d\theta} \int T(x_1, \dots, x_n) f(x_1, \dots, x_n; \theta) dx_1, \dots, dx_n$$

SCAMBIO DERIVATA

E INTEGRALE $\rightarrow$ $= \int T(x_1, \dots, x_n) \frac{d}{d\theta} f(x_1, \dots, x_n; \theta) dx_1, \dots, dx_n$

MOLTIPLICO E

DIVIDO PER

$f(x_1, \dots, x_n; \theta)$

$$= \int T(x_1, \dots, x_n) \frac{d}{d\theta} \frac{f(x_1, \dots, x_n; \theta)}{f(x_1, \dots, x_n; \theta)} f(x_1, \dots, x_n; \theta) dx_1, \dots, dx_n$$

S_n : DERIVATA DELLA $\log L$

$$= E[S_n, T_n] = \text{Cov}(S_n, T_n)$$

NOTA: $\text{COV}(X, Y) = E[XY] - E[X]E[Y]$ NEL NOSTRO CASO $E[X] = E[S_n] = 0$
 $\Rightarrow \text{COV}(X, Y) = E[XY]$.

UN STIMATORE RAGGIUNGE IL MINIMO QUANDO LA DISUGUAGLIANZA DI C-SW DIVENTA UN'UGUAGLIANZA, OVVERO QUANDO SONO **LINEARMENTE DIPENDENTI**.

COROLLARIO: SOTTO LE CONDIZIONI DI REGOLARITA', E SIA T_n NON DISTORTO ($E[T_n] = \theta_0$), RAGGIUNGE IL LIMITE INFERIORE DI Cramer-Rao SE $\exists \alpha(\theta)$:

$$\alpha(\theta)(T_n - \theta) = S_n(\theta)$$

OSSIA LO STIMATORE $\bar{E}$ UNA COMBINAZIONE LINEARE DELLA SCORE FUNCTION.

Caso $d > 1$

$$- E[(T_n - \theta)(T_n - \theta)^T] \geq I_n^{-1}(\theta_0)$$

→ MATRICE DI COVARIANZA DI T_n . SULLA DIAGONALE CI SONO LE VARIANZE DEI SINGOLI COMPONENTI E FUORI LE DIAGONALI LE COVARIANZE

$$- \text{VAR}(T_n) \geq (J\psi) I_n^{-1}(\theta_0) (J\psi)^T$$

↳ MATRICE DERIVATE PARZIALI: JACOBIANO